

硕士学位论文

基于卷积神经网络的轴承故障
诊断算法研究

**STUDY ON BEARING FAULT DIAGNOSIS
ALGORITHM BASED ON CONVOLUTIONAL
NEURAL NETWORK**

张伟

哈尔滨工业大学
2017 年 6 月

国内图书分类号：TP277

学校代码：10213

国际图书分类号：621

密级：公开

工学硕士学位论文

基于卷积神经网络的轴承故障 诊断算法研究

硕士研究生：张伟

导师：彭高亮 副教授

申请学位：工学硕士

学科：机械电子工程

所在单位：机电工程学院

答辩日期：2017年6月

授予学位单位：哈尔滨工业大学

Classified Index: TP277

U.D.C: 621

Dissertation for the Master Degree in Engineering

**STUDY ON BEARING FAULT DIAGNOSIS
ALGORITHM BASED ON CONVOLUTIONAL
NEURAL NETWORK**

Candidate:	Zhang Wei
Supervisor:	Peng Gaoliang, Associate Professor
Academic Degree Applied for:	Master of Engineering
Speciality:	Mechatronic Engineering
Affiliation:	School of Mechatronics Engineering
Date of Defence:	June, 2017
Degree-Conferring-Institution:	Harbin Institute of Technology

摘要

机电装备朝着大型化、高速化、精密化、系统化和自动化的方向发展。建立可靠的健康检测系统,是保证机电装备平稳运行的关键。随着设备检测点的数量与采样频率的增加,机械健康监测进入了“大数据”时代。基于信号处理的特征提取+分类器的传统智能诊断算法,对专家经验要求高,设计耗时且不能保证通用性,已经不能满足机械大数据的要求。本文针对该问题,以机械中最重要的零件轴承为研究对象,提出了一套基于卷积神经网络智能诊断算法,该算法可以自动完成特征提取以及故障识别。

本文首先提出了具有两个卷积层的卷积神经网络,对时域振动信号进行诊断。利用数据集增强技术,模型在 CWRU 轴承数据库上的识别率达到了 99%以上。该模型是第一个直接作用在时域振动信号上,对轴承进行故障诊断的卷积神经网络。

通过进一步分析振动信号的特点,提出了用于轴承故障诊断的卷积神经网络框架 WDCNN 模型。该模型具有第一层大卷积核以及多层小卷积核的鲜明特征。利用批量归一化算法,模型的训练速度很快。给出了 WDCNN 模型的设计准则,降低了故障诊断算法的设计难度。WDCNN 在 CWRU 数据库上的识别率可以达到 100%。

针对噪声以及变负载情况下,轴承故障诊断系统识别率会降低的问题。本文首次将这两类问题共同归结为机器学习中的领域自适应问题,并引入了自适应批量归一化算法,对 WDCNN 模型进行改进。该算法大幅提高了 WDCNN 模型的抗噪性以及变负载自适应性。针对神经网络难以分析的难题,利用数据可视化技术,展示了 WDCNN 模型诊断轴承故障信号的过程。

针对自适应批量归一化算法需要测试集的统计信息的不足,提出了 TICNN 模型。TICNN 模型利用卷积核 Dropout 与极小批量训练,为卷积神经网络引入训练干扰,增强了模型的泛化性能。为了进一步提高网络性能,使用集成学习来提高模型的识别率与稳定性。TICNN 模型不需要任何测试集的信息,无需任何降噪预处理,取得了很高抗噪与变负载自适应性能。

关键词: 轴承故障诊断; 卷积神经网络; 抗噪性; 变负载自适应性

Abstract

Mechanical equipment is becoming much larger, faster, more precise, more systematic and more autonomous in current industrial society. The key to ensure the safety of machine is to set up reliable health monitoring system. The mechanical health condition monitoring is entering the age of ‘big data’ for much more monitoring points and sampling rate. Traditional intelligent fault diagnosis methods based on signal processing and classifier cannot meet the requirements of mechanical big data, because those methods need proficient experience of experts, much time to design and cannot ensure their general ability. This paper proposed a series of intelligent bearing fault diagnosis methods based on convolutional neural network to address the problem above, the proposed methods can automatically extract features and detect the faults without any expert experience.

First, this paper presents a convolutional neural network with two convolutional layers to diagnose the temporal vibration signals. With the help of data augment, this model can achieve more than 99% accuracy on CWRU bearing dataset. The proposed model was the first convolutional model which works directly on the temporal vibration signal for bearing fault diagnosis.

Second, a convolutional neural network framework named WDCNN for bearing fault diagnosis is presented. This model works directly on vibration signals and is featured as follows: it has large first-layer convolutional kernels and very small convolutional kernels in the following layers. The model is easy to train because of the batch normalization layers. Besides, it is easy to design the model with the given design rules. WDCNN can obtain 100% accuracy on CWRU bearing dataset.

Third, the noisy environment and various working load problems which can degrade the performance of diagnosis system are addressed. This paper treated the problems as domain adaptation problems in machine learning, and introduced adaptive batch normalization algorithm to improve the performance of WDCNN model. As result, this method helps WDCNN model hold high accuracy in noisy and various working load environment. In addition, visualization technologies are employed to show the signal processing of WDCNN.

Last, TICNN model is proposed to cover the shortage of adaptive batch normalization method which needs statistics of all the testing samples. First layer convolutional kernels with changing dropout rate and small mini-batch training are employed as training interference to train the neural network, which enhance the general ability of the model. Ensemble learning is used to improve the accuracy and stability of the model. Although no information of testing samples and any other denoising pre-processing methods are used in TICNN model, TICNN can perform well in noisy and

various working load environment.

Keywords: bearing fault diagnosis, convolutional neural network, anti-noise ability, adaptivity under various working load

目录

摘要	I
Abstract	II
目录	IV
第 1 章 绪论	1
1.1 课题背景及研究意义	1
1.2 轴承智能故障诊断算法研究现状及分析	2
1.2.1 国外研究现状	2
1.2.2 国内研究现状	3
1.3 卷积神经网络研究现状	4
1.4 综述与简析	6
1.5 本文主要研究内容	7
第 2 章 基于一维卷积神经网络的滚动轴承故障诊断方法	9
2.1 引言	9
2.2 卷积神经网络结构	9
2.2.1 卷积层	9
2.2.2 激活层	10
2.2.3 池化层	11
2.2.4 全连接层	12
2.2.5 目标函数	12
2.2.6 用于滚动轴承故障诊断的一维卷积神经网络结构	13
2.3 卷积神经网络误差反向传播	14
2.3.1 全连接层反向求导	14
2.3.2 池化层反向求导	15
2.3.3 卷积层反向求导	15
2.4 Adam 优化算法	15
2.5 数据集增强	16
2.6 滚动轴承故障诊断试验	17
2.6.1 凯斯西储大学轴承数据库	17
2.6.2 故障诊断结果	18
2.7 本章小结	20
第 3 章 轴承故障诊断深度卷积神经网络架构	21

3.1 引言	21
3.2 WDCNN 算法描述	21
3.3 批量归一化层 (BN)	22
3.3.1 BN 的正向传播	22
3.3.2 BN 的反向求导	23
3.4 WDCNN 超参数设计准则	24
3.5 WDCNN 轴承故障诊断试验	25
3.5.1 WDCNN 试验参数	25
3.5.2 WDCNN 试验模型及训练	26
3.5.3 故障诊断结果	27
3.6 本章小结	29
第 4 章 基于 AdaBN 算法的 WDCNN 轴承故障诊断模型	30
4.1 引言	30
4.2 基于 AdaBN 算法的 WDCNN 模型	30
4.3 噪声环境下轴承故障诊断性能分析	31
4.3.1 噪声信号准备	31
4.3.2 第一层卷积核大小对抗噪性影响	32
4.3.3 抗噪性比较	33
4.4 变载情况下故障诊断性能分析	34
4.4.1 变载问题描述	34
4.4.2 试验结果与分析	35
4.5 WDCNN 模型可视化分析	36
4.5.1 第一层卷积核可视化	36
4.5.2 神经元可视化	37
4.5.3 分类过程可视化	39
4.6 本章小结	40
第 5 章 基于训练干扰的 WDCNN 轴承故障诊断模型	41
5.1 引言	41
5.2 TICNN 模型	41
5.2.1 TICNN 模型结构	41
5.2.2 卷积核 Dropout 算法	42
5.2.3 极小批量训练	44
5.2.4 基于多数同意规则的集成学习	45

5.3 TICNN 模型训练过程	46
5.4 TICNN 抗噪性分析	48
5.4.1 Mini-batch 大小对 TICNN 抗噪性能的影响	48
5.4.2 卷积核 Dropout, BN 与集成学习对 TICNN 抗噪性的影响	49
5.4.3 抗噪性比较	50
5.5 TICNN 变载情况下轴承故障诊断率分析	51
5.6 TICNN 模型可视化分析	51
5.6.1 第一层卷积核可视化	52
5.6.2 神经元可视化	52
5.6.3 分类过程可视化	53
5.7 本章小结	55
结论	56
参考文献	57
攻读学位期间发表的学术论文	61
哈尔滨工业大学学位论文原创性声明和使用权限	62
致 谢	63

第1章 绪论

1.1 课题背景及研究意义

机电装备朝着大型化、高速化、精密化、系统化和自动化的方向发展。为了维持设备的安全运行,对主要零部件的健康状况必需进行实时监控^[1]。《中国制造 2025》重点领域技术路线图特别指出^[2],对航空发电机、先进轨道交通装备、发电装备以及农业装备等要实现实时故障诊断。特别是航空发电机,报告明确指出,必须开发具有状态监视、故障诊断与处理、故障预测和寿命管理功能的先进健康管理系统。

由于现代化机电装备规模大,监测点多,传感器采样频率高,设备服役周期长,检测系统将获得海量的数据。例如,三一重工对搅拌车、起重机、泵车等十大类、百余种工程机械设备进行在线监测,监测超过 10 万台的设备,每台设备包含 246 个测点,该系统以每天 1000 条数据的速度增长。北京化工大学高金吉等人在 29 个企业共监测 1149 台设备,总检测点数为 18552 个,数据量也达到 1.52TB。以上例子表明,机电装备的状态监测迈入“大数据”时代^[3]。

机电产品大数据给故障诊断带来新的挑战,有三大特点^[4]:

(1) 数据量大,专业分析人员的数量严重不足,仅依靠人力进行检测已不能满足要求,亟需能够进行自动诊断的智能算法。

(2) 数据类型多样化,每条数据来源于不同机械设备,工况,以及物理位置,数据特征难挖掘,诊断的难度加大

(3) 高速率情况下,装备中各零部件的联系更加紧密,一个零件的微小故障很可能引发连锁发应,致使整个设备瘫痪。

针对以上三个特征,在机电大数据时代,如何从海量数据中自动挖掘特征,逐渐取代专家进行特征提取,对轴承等重要零件进行实时检测,并保证故障诊断及预测的准确性与高效性,是重中之重。

轴承是旋转机械中最关键的零件之一,在旋转机械发生故障时,约 30%是轴承故障^[5]。例如,国内某钢铁公司的高线初轧机因为一个齿轮箱的主输出轴轴承破碎,造成了 1400 万元以上的经济损失^[6]。2000 年,三峡工程由于塔带机的轴承选型不当,致使皮带机在检修中发生坠落事故,造成严重的人员伤亡与财产损失^[7]。因此,本文将以轴承为例,探索一种新的算法,实现轴承故障的智能诊断。

近 5 年来,卷积神经网络在模式识别领域取得了巨大的成功^[8]。这类技术的特点是,可以自动从信号和图像中挖掘特征,取代了传统算法繁琐的特征工程。卷积神经网络由于参数较多,需要比常规算法使用更多的训练数据进行训练,抑制过拟合。这也是卷积神经网络在大数据时代逐渐脱颖而出的原因。

综上,在机电大数据时代,智能故障诊断算法的需求量急剧增加;而卷积神经网络以大数据为引擎,是当下效果最好的模式分类算法。因此,两者相辅相成,两者的结合将有广阔的前景。

1.2 轴承智能故障诊断算法研究现状及分析

轴承故障诊断时机械状态监测的热门研究方向,其算法的核心在于信号特征提取与模式分类两个部分。在轴承故障诊断领域,常见的特征提取算法有快速傅里叶变化^[9],小波变换^[10],经验模式分解^[11]以及信号的统计学特征^[12]等,常见的模式分类算法有支持向量机^[13],BP 神经网络^[14](也称为多层感知器),贝叶斯分类器^[15]以及最近邻分类器^[16]等。当下轴承故障诊断的研究热点是可以归结为 3 类:寻找更好的特征表达;寻找最适合的特征表达以及分类器的组合;以及发明新的传感器。以下将分别介绍国内外在故障诊断领域的最新进展。

1.2.1 国外研究现状

2013 年,印度理工学院的 Nishchal 等人^[17]利用堆叠式稀疏自编码器(SAE, Stacked Sparse Auto-encoder)提取稀疏特征,对轴承以及阀门进行故障诊断。研究人员分别从时域,频域以及小波域提取了 87 个特征,再将这 87 个特征作为深度网络的输入,逐层训练稀疏自编码器。最后利用支持向量机对整个深度网络进行有监督微调,取得了 95.96%的诊断正确率。

2015 年,法国第十一大学的 Jinane 等^[18]提出了一种新的特征提取方法,即全局谱分析(Global Spectrum Analysis),来分析轴承振动信号。该方法首先使用包络检测与快速傅里叶变换进行信号预处理,经过主频特征选择,再通过主成分分析来提取主特征,最后利用线性判别器进行分类。该方法的优点是不依赖先验知识,并且可以获得很好的分类结果。

2016 年,德国亚琛工业大学 Christelle 等^[19]提出使用电流信号来诊断轴承故障。该方法首先计算故障主频率,再建立由标准差,峰度,偏度,波峰因子,间隙与形状因子等六个统计学参数构成的特征矩阵,接着使用线性判别器进行特征降维,最后利用贝叶斯分类器进行故障分类。该方法的优点是无需安装传感器就可以进行诊断,缺点是在小负载的情况下,几乎无法实现诊断。

2016 年,瑞典吕勒奥理工大学 Georgoulas 等^[20]提出了一种用于轴承故障诊断的振动信号特征融合方法。该方法适用于具有两个加速度计的诊断系统,作者利用协方差矩阵进行特征融合,然后分别使用主成分分析异常检测器,最近邻异常检测器以及高斯异常检测器进行故障诊断,然后使用多数同意规则进行集成。该方法在试验系统可以达到 100%的识别率。

2016 年,比利时根特大学 Janssen 等人^[21],首次利用卷积神经网络对齿轮箱中

的轴承、齿轮等故障诊断。该网络由一个卷积层与一个全连接层组成。首先对信号进行离散傅里叶变换，将原始的时域振动信号转换到频域，再直接训练卷积神经网络实现故障诊断，该方法在试验系统中，将常规算法的故障诊断率提高了 6%。

2017 年，美国伊利诺伊大学芝加哥分校的 David 等^[22]提出了大内存存储检索网络 LAMSTAR (large memory storage retrieval)，对轴承进行故障诊断。LAMSTAR 如图 1-1 所示，该网络由一个输入层，多个输入自组织映射 SOM (self-organizing maps) 模块，以及一个决策 SOM 模块构成。输入 SOM 模块隐含层，用来提取特征，决策 SOM 是输出层。作者首先对传感信号进行短时傅里叶变换，获取传感信号的频谱图，再用 LAMSTAR 进行分类。该算法在不同的转速下的诊断率均达到了 96%以上。




图 1-1 LAMSTAR 结构图^[22]

1.2.2 国内研究现状

近两年，国内在轴承智能故障诊断领域，特别是利用数据驱动的特征提取技术进行故障诊断，处于世界领先地位。国内清华大学，中国科学与技术大学，西安交通大学与东南大学等是最早开展该研究的大学，本小节将重点介绍他们的研究成果。

2015 年，清华大学的王学谦等^[23]利用堆叠式的稀疏自编码器构建深度神经网络，对滚动轴承进行故障诊断。该网络采用逐层训练的方式，前一层作为一个稀疏自编码器的输入层，后一层作为其隐含层，由下往上逐层训练，最后再使用有监督学习进行网络参数微调。为了达到降噪的目的，作者先对时域的振动信号采用了小波变换。作者对美国凯斯西储大学 CWRU (Case Western Reserve University) 轴承数据库进行诊断，结果表明该方法优于传统的 BP 网络。

2016 年,东南大学的严如强等^[24]利用基于降噪稀疏自编码器(Denoising Sparse Auto-encoders)的深度神经网络,来诊断轴承与电机的故障。如图 1-2 所示,先训练一层降噪稀疏自编码器来提取特征,将训练好的编码器的前两层,接上一个全连接层,构建一个三层的深度网络,最后利用有监督训练对网络的权值进行更新。该算法的故障诊断正确率高于含有两个隐含层的 BP 网络,可以达到 97.61%的识别率。




图 1-2 基于稀疏自编码器的深度神经网络结构^[24]

2016 年,中国科技大学的竺长安等人^[25]利用深度置信网络,提出使用分层诊断网络 HDN(Hierarchical Diagnosis Network),对滚动轴承进行故障诊断。该方法先使用 DBN 确定轴承损伤位置,即无缺陷,内圈,外圈与滚动体缺陷的诊断,再用 DBN 对损伤的大小进行诊断,诊断的结果一共 10 类。利用该分层结构,对采样频率为 12kHz 的 CWRU 的轴承数据进行分类,在 BPNN 与 SVM 分别达到 95.14% 与 96.48% 的基础上,DBN 达到了 99.03% 的诊断正确率。

2016 年,西安交通大学雷亚国等^[26]提出一个四层的深度神经网络进行轴承故障诊断。首先对 2400 个数据进行快速傅里叶变换,再用自编码器进行无监督逐层预训练,最后再进行有监督训练。该算法在采样频率为 48kHz 的 CWRU 轴承数据库上的识别率达到了 $99.68 \pm 0.22\%$

1.3 卷积神经网络研究现状

卷积神经网络(CNN, Convolutional Neural Network)由 Yann LeCun 在 1989 年提出,用于手写数字识别^[27]。卷积神经网络在模式分类领域有着广泛的应用,其特点是,在 CNN 的输入端直接输入原始图像与信号,而输出端直接输出结果,无需特征提取等预处理环节。这种方式也被称为“端到端”的识别过程。2012 年,加拿大多伦多大学 Krizhevsky 设计了具有 5 个卷积层的深度卷积神经网络 AlexNet^[28],如图 1-3 所示,该模型获得了 ImageNet 挑战赛的冠军,拉开了深度学习的热潮。深度学习也因此被《MIT Technology Review》评为 2013 年十大突破技术之首^[29]。

经过五年的高速发展，深度卷积神经网络取得了多项重大成果。




图 1-3 AlexNet 结构图^[28]


2015 年，微软研究院何恺明等提出残差卷积神经网络 ResNet，在计算机视觉历史上，首次取得高于人眼的图像识别率^[30]。该网络利用恒等映射层，可以将原始输入信号传递到最后一层，解决了深度神经网络的梯度弥散问题，最终设计出高达 152 层的卷积神经网络。该模型在斯坦福大学 ImageNet 挑战中的错误率仅为 4.94%，低于试验中人眼辨识 5.1%的错误率，

2016 年，麻省理工大学 Yusuf 等提出了著名的 SoundNet^[31]，利用无标签视频学习出声音特征，以最少的样本标定代价，学习到了十分丰富的特征。该方法利用二维卷积神经网络提取视频的特征，再利用一维卷积神经网络提取音频特征，用两个网络输出的 KL 散度作为目标函数。利用该方法提取的特征，大幅提高了音频分类的识别率。

2016 年与 2017 年，DeepMind 团队的 AlphaGo^[32]先后战胜了围棋手李世石与柯洁，体现了当前世界上人工智能的最高水平。根据发表在《Nature》封面上的论文，AlphaGo 是由两套卷积神经网络和一棵蒙特卡洛树组成。如图 1-4 所示，其中一套卷积神经网络为策略网络，用于决定下一步落子的位置，另一套卷积神经网络是价值网络，用于评估当前棋局获胜的概率。可见卷积神经网络是 AlphaGo 获胜的关键。

2017 年，斯坦福大学的 Esteva 等在《Nature》上发表封面文章^[33]，称该团队设计的卷积神经网络，在皮肤癌的诊断上，首次达到了人类专家的水平。该网络使用约 13 万幅临床图像，包含 2032 种疾病类型的数据集，用来训练卷积神经网络，正确诊断率达到了 91%以上。这是目前人工智能算法，在医疗领域取得的最重大的突破。

综上，卷积神经网络的在二维图像识别与诊断，一维音频分类等领域取得了重大突破。有理由相信，卷积神经网络可以为当下故障诊断算法提供新的思路，提高当下故障诊断算法的诊断性能。


 图 1-4 AlphaGo 神经网络训练流程图以及结构^[32]

1.4 综述与简析

综合国内外对轴承智能诊断算法的研究来看，所有的算法均可以分为特征提取与分类器分类两个部分，如图 1-5 所示。在使用支持向量机等传统分类器的情况下，为了抑制过拟合并降低计算量，还会对提取出的特征进行降维操作。利用数据驱动的特征提取技术，大多采用堆叠式预训练的深度学习神经网络，由于网络本身的逐层预训练已经使用自编码器等进行了降维，所以可以省去特征降维的操作。




图 1-5 轴承智能诊断算法步骤分解

可以看出，一个智能故障诊断系统的成功与否，关键在于特征提取器与分类器的选择。不同的方法本质上都在寻找一种最优的组合，使最后的识别率最高。目前智能诊断算法的研究存在以下几个问题：

1) 在一个机械系统中表现很好的特征提取器与分类器组合，当装置变化时，不能保证其能否继续保持高识别率，即算法组合的通用性不能保证。这也是不同的文章中的诊断算法都不相同的原因。

2) 在进行故障诊断时，需要先分析机械系统的内在运行机理，再利用信号处

理技术分析故障信号。这种做法，对设计人员的技术要求高，难度较大。

3) 目前利用数据驱动的特征提取方法，需要预先对信号进行快速傅里叶变换或者小波变换，这种做法存在丢失重要时域特征的可能。

为了解决以上问题，最理想的方式是将特征提取与分类两个环节合二为一，这样不存在相互组合的难题，无需分析机械装置的内在机理，由于直接作用在原始信号上，也不会造成信息的缺失。

如 1.3 节所述，卷积神经网络具有“端到端”的特点，即可以通过一个神经网络完成特征提取、特征降维与分类器分类这一整套过程。卷积神经网络的这个特点无疑弥补了当下故障诊断方式的不足，为故障诊断提供了一种崭新的研究思路。

1.5 本文主要研究内容

本文主要研究基于卷积神经网络的轴承故障诊断。在文章前半部分，着重研究如何设计适用于轴承故障诊断的卷积神经网络，研究重点是直接作用在原始时域信号上，并且要达到高识别率。在文章后半部分，主要对设计出的卷积神经网络进行改进，使改进后的网络在噪声环境，以及在工作负载变化时，依然可以保持高识别率。每一章的主要内容如下所示：

(1) 建立作用在时域信号上的轴承故障诊断 CNN 模型

针对轴承故障信号的特点，设计了包含两个卷积层的卷积神经网络模型，用于故障诊断。该模型直接作用在原始的时域振动信号上，层数少，计算量小，识别率高，可塑性强，是以下几章的研究基础。

(2) 提出面向轴承故障诊断的统一框架：第一层宽卷积核深度卷积神经网络

借鉴当下的深度学习技术，提出了第一层宽卷积核深度卷积神经网络 (WDCNN)，其主要特征是具有第一层大卷积核与多层 3×1 小卷积核。文中给出了 WDCNN 模型的设计准则与细节，降低了卷积神经网络的设计难度。WDCNN 模型收敛速度快，在大数据训练下，对采样频率为 12kHz 的凯斯西储大学轴承数据库可以达到 $100\% \pm 0$ 的识别率。

(3) 提出基于自适应批量归一化算法的 WDCNN 模型

噪声干扰以及负载变化，会造成振动信号发生变化，导致 WDCNN 模型的识别率降低。文中将以上问题归结为机器学习中的领域自适应问题，并提出利用自适应批量归一化 (AdaBN) 算法对 WDCNN 模型进行改进。在使用目标领域均值方差的情况下，AdaBN 显著提高了 WDCNN 的抗噪性与变负载自适应性能。

(4) 提出基于训练干扰模型增强 WDCNN 的泛化性能

针对 AdaBN 需要目标领域样本均值方差的不足，提出了基于训练干扰的卷积神经网络 (TICNN)。TICNN 模型在 WDCNN 模型的训练过程中引入了卷积核

Dropout 和极小 mini-batch，并采用集成学习。该模型在没有利用任何目标领域的信息情况下，依然具有很高的抗噪性与负载自适应性。

第2章 基于一维卷积神经网络的滚动轴承故障诊断方法

2.1 引言

目前,在轴承智能故障诊断算法中,基于信号处理的特征提取是必要环节,该环节耗时并且对专家经验要求高,给诊断系统的实时性与设计成本带来严重负担。针对以上问题,本章提出了一种端到端的诊断算法,省去了人为特征提取过程,即基于卷积神经网络的轴承故障诊断算法。

本章将介绍所使用的一维卷积神经网络的基本单元,反向求导公式,网络整体结构,优化训练算法,以及用于轴承故障诊断的数据集增强方法。最后,通过试验验证该卷积神经网络的性能。

2.2 卷积神经网络结构

卷积神经网络是多级神经网络,包含滤波级(filtering stage)与分类级(classification stage)。其中,滤波级用来提取输入信号的特征,分类级对学习到的特征进行分类,两级网络参数是共同训练得到的^[8]。滤波级包含卷积层(convolutional layers),池化层(pooling layers)与激活层(activation layers)等3个基本单元,而分类级一般由全连接层组成。本章设计的卷积神经网络处理的是一维信号,故本节将对一维卷积神经网络的基本单元进行介绍。

2.2.1 卷积层

卷积层使用卷积核(Convolutional Kernels)对输入信号(或特征)的局部区域进行卷积运算,并产生相应的特征。卷积层最重要的特点是权值共享(Weights Sharing),即同一个卷积核将以固定的步长(Stride)遍历一次输入。权值共享减少了卷积层的网络参数,避免了由于参数过多造成的过拟合,并且降低了系统所需内存。在实际操作中,大多使用相关运算(Correlation Operation)来替代卷积运算^[34],这样可以避免反向传播时翻转卷积核。具体的卷积层运算如式(2-1)所示:

$$y^{l(i,j)} = \mathbf{K}_i^l * \mathbf{x}^{l(r^j)} = \sum_{j'=0}^{W-1} \mathbf{K}_i^{l(j')} \mathbf{x}^{l(j+j')} \quad (2-1)$$

式中 $\mathbf{K}_i^{l(j')}$ ——第 l 层的第 i 个卷积核的第 j' 个权值;

$\mathbf{x}^{l(r^j)}$ ——第 l 层中第 j 个被卷积的局部区域;

W ——卷积核的宽度。

一维卷积层的运算过程如图 2-1 所示。图中一共有 4 个卷积核,每个卷积核均遍历一次卷积层,同时进行卷积运算。以第一个卷积核为例,在进行卷积操作时,

卷积核与被卷区域的神经元对应的系数相乘，得到第一个 logits 值 $y^{l(1,1)}$ ，然后以步长为 1 移动卷积核，重复之前的操作，直至卷积核遍历完输入信号的所有区域。




图 2-1 一维卷积层示例图

2.2.2 激活层

经过卷积操作之后，激活函数将对每一个卷积输出的 logits 值进行非线性变换。激活函数的目的，是将原本线性不可分的多维特征映射到另一空间，在此空间内，特征的线性可分性将增强。神经网络中常用的激活函数有 Sigmoid 函数，双曲正切函数 Tanh 以及修正线性单元 ReLU (Rectified Linear Unit)。三种激活函数的具体表达如式 (2-2)、(2-3) 与 (2-4) 所示：

$$a^{l(i,j)} = \text{Sigmoid}(y^{l(i,j)}) = \frac{1}{1 + e^{-y^{l(i,j)}}} \quad (2-2)$$

$$a^{l(i,j)} = \text{Tanh}(y^{l(i,j)}) = \frac{e^{y^{l(i,j)}} - e^{-y^{l(i,j)}}}{e^{y^{l(i,j)}} + e^{-y^{l(i,j)}}} \quad (2-3)$$

$$a^{l(i,j)} = f(y^{l(i,j)}) = \max\{0, y^{l(i,j)}\} \quad (2-4)$$

式中 $a^{l(i,j)}$ ——卷积层输出 $y^{l(i,j)}$ 的激活值。

三种常见激活函数的曲线图如图 2-2 所示。当输入值的绝对值较大时，Sigmoid 与 Tanh 函数的导数值均接近 0，这会造成利用误差反向传播来更新权值时，随着神经网络层数的增加，误差值无法向下传播，从而底层网络训练不透，这也被称为

梯度弥散现象。而 ReLU 函数在输入值大于 0 的导数值始终为 1，很好的克服了梯度弥散现象，因此，在本文中，将采用 ReLU 作为卷积神经网络的激活函数。




图 2-2 三种常见的神经网络激活函数

2.2.3 池化层

池化层（Pooling Layer）进行的是降采样操作，主要目的是减少神经网络的参数。一维池化操作的示例如图 2-3 所示，图中输入层的特征宽度为 6，深度为 4，通过大小、步长均为 2 的池化操作，将原始特征降采样到宽度为 3，深度为 4 的输出特征。




图 2-3 一维池化操作示意图

常用的池化函数有均值池化（Average Pooling）与最大值池化（Max Pooling）。均值池化是将感知域的神经元的均值作为输出值，而最大值池化是将感知域中的最大值作为输出，两者数学描述如式（2-5）、（2-6）所示。

$$p^{l(i,j)} = \frac{1}{W} \sum_{t=(j-1)W+1}^{jW} a^{l(i,t)} \quad (2-5)$$

$$p^{l(i,j)} = \max_{(j-1)W+1 \leq t \leq jW} \{a^{l(i,t)}\} \quad (2-6)$$

式中 $a^{l(i,t)}$ ——第 l 层第 i 帧第 t 个神经元的激活值；

W ——池化区域的宽度；

$p^{l(i,j)}$ ——池化区域的宽度

本文中采用的降采样操作为最大值池化。这样做的优点在于可以获得位置无关的特征，这一点对于周期性的时域信号很关键。

2.2.4 全连接层

全连接层是将滤波级提取出的特征进行分类。具体做法为，先将最后一个池化层的输出，铺展成一维的特征向量，作为全连接层的输入；再将输入与输出之间进行全连接，如图 2-4 所示，其中隐含层使用的激活函数为 ReLU，最后输出层采用的是激活函数是 Softmax 函数。Softmax 函数的目的是将输入的神经元转化为和为 1 的概率分布，这样做有利于后续的多分类目标函数的建立。




图 2-4 一维池化操作示意图

全连接层的正向传播公式如下式所示：

$$z^{l+1(j)} = \sum_{i=1}^n \mathbf{w}_{ij}^l \mathbf{a}^{l(i)} + b_j^l \quad (2-7)$$

式中 $\mathbf{w}_{ij}^l$ ——第 l 层第 i 个神经元与第 $l+1$ 层第 j 个神经元之间的权值；

z_j^{l+1} ——第 $l+1$ 层第 j 个输出神经元的 logits 值。

b_j^l ——第 l 层所有神经元对第 $l+1$ 层第 j 个神经元的偏置值。

当 $l+1$ 层为隐含层时，激活函数为 ReLU：

$$\mathbf{a}^{l+1(i)} = \max\{0, z^{l+1(j)}\} \quad (2-8)$$

当 $l+1$ 层为输出层时，激活函数为 Softmax：

$$q^j = \text{softmax}(z^{l+1(j)}) = \frac{e^{z^{l+1(j)}}}{\sum_k^{10} e^{z^{l+1(k)}}} \quad (2-9)$$

2.2.5 目标函数

一段输入信号在神经网络的输出应当与它的目标值一致，评价这种一致性的函数叫做神经网络的目标函数（Objective Function），也称为损失函数（Loss Function）。常用目标函数有平方误差函数（Squared Loss Function）以及交叉熵损

失函数 (Cross-entropy Loss Function)。假设卷积神经网络的实际输出的 Softmax 值为 q ，其目标分布 p 为 one-hot 类型的向量，即当目标类别为 j 时， $p^j = 1$ ，否则 $p^j = 0$ 。则以平方误差函数，以及交叉熵函数为目标函数表达式如图式 (2-10) 与 (2-11) 所示：

$$L = \frac{1}{m} \sum_{k=1}^m \frac{1}{2} \sum_j (p_k^j - q_k^j)^2 \quad (2-10)$$

$$L = -\frac{1}{m} \sum_{k=1}^m \sum_j p_k^j \log q_k^j \quad (2-11)$$

式中 m ——输入的小批量 (mini-batch) 的大小。

与平方误差函数比较每一个类别的大小不同，交叉熵函数是衡量两个概率分布的一致性。交叉熵函数在机器学习中常被看做是 softmax 分布的负对数似然，因此本文将采用交叉熵函数作为目标函数。

2.2.6 用于滚动轴承故障诊断的一维卷积神经网络结构

本章提出的卷积神经网络的结构如图 2-5 所示。该卷网包含两个卷积层，两个池化层，一个全连接隐含层，以及一个 Softmax 层。诊断信号通过第一个卷积层以及 ReLU 激活层，变为一组特征图 (Feature Maps)，再经过最大值池化进行降采样。重复一次以上操作，将最后一个池化层的特征图与全连接隐含层相连，经过 ReLU 激活之后，传递到最后的 softmax 层。卷积神经网络的结构参数如表 2-1 所示，第一层卷积核大小为 20×1 ，步长为 8×1 ，第二层卷积核大小为 5×1 ，步长为 2×1 。第一个池化层的区域大小为 4×1 ，第二个池化区域大小为 2×1 。全连接层的神经元个数为 500。




图 2-5 一维卷积神经网络结构图

表 2-1 一维卷积神经网络结构参数

编号	网络层	卷积核大小/步长	卷积核数目	输出大小(宽度 × 深度)	零补
1	卷积 1	$20 \times 1/8 \times 1$	32	256×32	是
2	池化 1	$4 \times 1/4 \times 1$	32	64×32	否
3	卷积 2	$5 \times 1/2 \times 1$	64	32×64	是
4	池化 2	$2 \times 1/2 \times 1$	64	16×64	否
5	全连接	500	1	500×1	
6	Softmax	10	1	10	

2.3 卷积神经网络误差反向传播

误差反向传播是对神经网络进行权值优化的关键步骤。主要做法是先求解目标函数关于最后一层神经元的导数，通过链式法则，从后往前逐层计算目标函数关于所有权值的导数值。因此，本节也将从全连接层开始，逐步求解每一层的导数值。

2.3.1 全连接层反向求导

首先，计算目标函数 L 关于最后一层 logits 值 $z^{l+1(j)}$ 的导数，如式 (2-12) 所示：

$$\frac{\partial L}{\partial z^{l+1(j)}} = \sum_{k=1}^m p_k^j q_k^j - p_k^j \quad (2-12)$$

再计算全连接层目标函数 L 关于全连接层的权值 $\mathbf{w}_{ij}^l$ 与偏置 b_j^l 的导数

$$\frac{\partial L}{\partial \mathbf{w}_{ij}^l} = \frac{\partial L}{\partial z^{l+1(j)}} \cdot \frac{\partial z^{l+1(j)}}{\partial \mathbf{w}_{ij}^l} = \frac{\partial L}{\partial z^{l+1(j)}} \cdot a^{l(i)} \quad (2-13)$$

$$\frac{\partial L}{\partial b_j^l} = \frac{\partial L}{\partial z^{l+1(j)}} \cdot \frac{\partial z^{l+1(j)}}{\partial b_j^l} = \frac{\partial L}{\partial z^{l+1(j)}} \quad (2-14)$$

最后，计算目标函数 L 关于激活函数为 ReLU 的全连接隐含层的激活值 $a^{l(i)}$ 以及 logits 值 $z^{l(i)}$ 的导数：

$$\frac{\partial L}{\partial a^{l(i)}} = \sum_j \frac{\partial L}{\partial z^{l+1(j)}} \cdot \frac{\partial z^{l+1(j)}}{\partial a^{l(i)}} = \sum_j \frac{\partial L}{\partial z^{l+1(j)}} \cdot \mathbf{w}_{ij}^l \quad (2-15)$$

$$\frac{\partial L}{\partial z^{l(i)}} = \frac{\partial L}{\partial a^{l(i)}} \cdot \frac{\partial a^{l(i)}}{\partial z^{l(i)}} = \begin{cases} 0 & \text{where } z^{l(i)} \leq 0 \\ \frac{\partial L}{\partial a^{l(i)}} & \text{where } z^{l(i)} > 0 \end{cases} \quad (2-16)$$

由 (2-16) 计算出 $\frac{\partial L}{\partial z^{l(i)}}$ 值后，可以根据 (2-13) 与 (2-14) 来求解目标函数 L 关于全连接隐含层的权值 $\mathbf{w}_{ij}^{l-1}$ 与偏置项 b_j^{l-1} 的导数。

2.3.2 池化层反向求导

当求解完目标函数 L 关于全连接层的 logits 值以及权值的导数后,接着要计算 L 关于池化层各参数的导数。由于池化层没有权值,所以只需计算 L 关于池化层的输入神经元的导数。对于最大值池化具体做法是:在正向传播时记录下池化区域的最大值位置,设当 $t = t_m$ 时, $\max_{(j-1)W+1 \leq t \leq jW} \{a^{l(i,t)}\} = a^{l(i,t_m)}$ 。在反向传播时,将导数值传递给第 t_m 个神经元,其他神经元不参与传递,即导数为 0。具体的公式描述如图 (2-17) 所示:

$$\frac{\partial L}{\partial a^{l(i,t)}} = \frac{\partial L}{\partial p^{l(i,j)}} \cdot \frac{\partial p^{l(i,j)}}{\partial a^{l(i,t)}} = \begin{cases} 0 & t \neq t_m \\ \frac{\partial L}{\partial p^{l(i,j)}} & t = t_m \end{cases} \quad (2-17)$$

2.3.3 卷积层反向求导

首先,计算 L 关于每个卷积层的 logits 值的导数,由于卷积层使用的是 ReLU 激活函数,故 $\frac{\partial L}{\partial y^{l(i,j)}}$ 的计算过程与式 (2-16) 类似,具体如式 (2-18) 所示:

$$\frac{\partial L}{\partial y^{l(i,j)}} = \frac{\partial L}{\partial a^{l(i,j)}} \cdot \frac{\partial a^{l(i,j)}}{\partial y^{l(i,j)}} = \begin{cases} 0 & \text{where } y^{l(i,j)} \leq 0 \\ \frac{\partial L}{\partial a^{l(i,j)}} & \text{where } y^{l(i,j)} > 0 \end{cases} \quad (2-18)$$

接着,计算 L 关于卷积层的输入值 $\mathbf{x}^{l(j)}$ 的导数,如式 (2-19) 所示:

$$\frac{\partial L}{\partial \mathbf{x}^{l(j)}} = \sum_i \frac{\partial L}{\partial y^{l(i,j)}} \cdot \frac{\partial y^{l(i,j)}}{\partial \mathbf{x}^{l(j)}} = \sum_i \frac{\partial L}{\partial y^{l(i,j)}} \cdot \sum_{j'=0}^{W-1} \mathbf{K}_i^l(j') \quad (2-19)$$

最后,计算 L 关于卷积核 $\mathbf{K}_i^l(j')$ 的导数,如式 (2-20) 所示:

$$\frac{\partial L}{\partial \mathbf{K}_i^l(j')} = \frac{\partial L}{\partial y^{l(i,j)}} \cdot \frac{\partial y^{l(i,j)}}{\partial \mathbf{K}_i^l(j')} = \frac{\partial L}{\partial y^{l(i,j)}} \cdot \sum_j \mathbf{x}^{l(j)} \quad (2-20)$$

2.4 Adam 优化算法

利用误差反向传播算法计算了目标函数每一个权值的导数之后,下一步就是用优化算法来更新权值,求解出最优的权值,使得目标函数的值达到最小,这个过程用公式描述如式 (2-21) 所示

$$\theta^* = \arg \min_{\theta} L(f(\mathbf{x}^i; \theta)) \quad (2-21)$$

式中 $L(\cdot)$ 、 $f(\cdot)$ ——目标函数值与输出值;

θ ——卷积神经网络的所有参数;

θ^* ——卷积神经网络的最优参数;

$\mathbf{x}^i$ ——卷积神经网络的输入。

对于浅层的神经网络，使用 BP 神经网络中经常采用的随机梯度下降 SGD (stochastic gradient descent) 便可以收敛到全局最优点。但是对本章中提出的深度卷积神经网络，由于参数及超参数多，如果超参数选择不好，使用 SGD 训练时往往陷入局部最优点。因此，本文中采了 Adam (adaptive moments) 算法^[35]。Adam 是一种学习率自适应的优化算法，它利用梯度的一阶矩估计和二阶矩估计，动态调整每个参数的学习率。Adam 的优点主要在于经过偏置校正后，修正从原点初始化的一阶矩（动量项）和（非中心的）二阶矩的估计，使得每一次迭代学习率都有个确定范围。Adam 通常对超参数的选择具有鲁棒性，因此对神经网络的参数调整很有帮助，其具体流程如表 2-2 所示。

表 2-2 Adam 优化算法流程

算法 1 Adam 算法	
输入:	学习率 λ ，矩估计指数衰减率 ρ_1 和 ρ_2 ，其中两者的默认值分别为 0.9 与 0.999，数值稳定常数 $\epsilon = 10^{-8}$ ，初始网络权值 θ ，初始化一阶矩，一阶矩与训练次数 $s = 0$ ， $v = 0$ 与 $t = 0$ 。
输出:	调整后的网络参数
While	没有达到训练终止条件
do	对样本个数为 m 的 mini-batch: $\{x^1, \dots, x^i, \dots, x^m\}$, 与之对应的目标值为 y^i
	$t \leftarrow t + 1$
	计算梯度: $g \leftarrow \frac{1}{m} \nabla_{\theta} \sum_{i=1}^m L(f(x^i; \theta))$
	更新有偏一阶矩估计: $s \leftarrow \rho_1 s + (1 - \rho_1) g$
	更新有偏二阶矩估计: $v \leftarrow \rho_2 v + (1 - \rho_2) g \odot g$
	修正一阶矩偏差: $\hat{s} \leftarrow \frac{s}{1 - \rho_1^t}$
	修正二阶矩偏差: $\hat{v} \leftarrow \frac{v}{1 - \rho_2^t}$
	权值更新: $\theta \leftarrow \theta - \lambda \frac{\hat{s}}{\sqrt{\hat{v} + \epsilon}}$
End while	

2.5 数据集增强

增强机器学习模型泛化能力最好办法是使用更多的训练样本^[34]。数据集增强 (Data Augment) 技术即通过增加训练样本，以达到增强深度神经网络泛化性能的目的。在计算机视觉领域，数据集增强的方式有图片镜像，旋转，平移，修剪缩放，调整对比度对等方法。然而，目前在故障诊断领域，并没有专门提出数据集增强技术，部分诊断算法的训练样本量很少^[1,25]，这样很容易造成过拟合。对于一维故障诊断信号，由于其特有时序性和周期性，图片的数据集增强技术并不完全适用。

本文提出的数据增强方式是重叠采样，即对于训练样本，从原始信号进行采集训练样本时，每一段信号与其后一段信号之间是有重叠的，采样方式如图 2-6 所示。对于测试样本，采集时没有重叠。假设一段故障诊断信号有 60000 个数据点，每次采集的训练样本长度为 2048，偏移量为 1，那么最多可以制作 57953 个训练

样本，可以很好的满足深度神经网络的训练需求。




图 2-6 数据集增强方式

2.6 滚动轴承故障诊断试验

2.6.1 凯斯西储大学轴承数据库

本文的试验数据来自于凯斯西储大学（CWRU）滚动轴承数据中心^[36]。CWRU 数据集是世界公认的轴承故障诊断标准数据集。截止到 2015 年，仅机械故障诊断领域顶级期刊《Mechanical Systems and Signal Processing》就发表过 41 篇使用 CWRU 轴承数据进行故障诊断的文章^[37]。在基于深度学习的轴承故障诊断领域，目前被引用数最高的两篇文章^[25,26]的试验数据也均来自 CWRU 轴承数据库。当下，轴承故障诊断算法更新较快，为了评价被提出算法的优越性，最客观的方式就是使用第三方标准数据库与当下主流算法比较。因此，本文的所有试验均采用 CWRU 轴承数据。

CWRU 轴承中心数据采集系统如图 2-7 所示。本试验的试验对象为图中的驱动端轴承，被诊断的轴承型号为深沟球轴承 SKF6205，有故障的轴承由电火花加工制作而成，系统的采样频率为 12kHz。被诊断的轴承一共有 3 种缺陷位置，分别是滚动体损伤，外圈损伤与内圈损伤，损伤直径的大小分别为包括 0.007inch, 0.014inch 和 0.021inch，共计 9 种损伤状态。试验中，每次使用 2048 个数据点进行诊断。为了便于训练卷积神经网络，对每段信号 x 均做归一化处理，归一化处理的公式如式（2-22）所示：

$$\tilde{x} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (2-22)$$

试验一共准备了 4 个数据集，如表 2-3 所示。数据集 A、B 和 C 分别是在负载为 1hp、2hp 和 3hp 下的数据集。每个数据集各包括 6600 个训练样本与 250 个测试样本，其中训练样本采用数据集增强技术，测试样本之间无重叠。数据集 D 是数据集 A、B 和 C 的并集，即包括了 3 种负载状态，一共有 19800 个训练样本与 750 个测试样本。




图 2-7 CWRU 滚动轴承数据采集系统

表 2-3 试验数据集描述

损伤位置		无				滚动体		内圈		外圈		负载
标签		1	2	3	4	5	6	7	8	9	10	
损伤直径(inch)		0	0.007	0.014	0.021	0.007	0.014	0.021	0.007	0.014	0.021	
A	训练	660	660	660	660	660	660	660	660	660	660	1
	测试	25	25	25	25	25	25	25	25	25	25	
B	训练	660	660	660	660	660	660	660	660	660	660	2
	测试	25	25	25	25	25	25	25	25	25	25	
C	训练	660	660	660	660	660	660	660	660	660	660	3
	测试	25	25	25	25	25	25	25	25	25	25	
D	训练	1980	1980	1980	1980	1980	1980	1980	1980	1980	1980	1,2,3
	测试	75	75	75	75	75	75	75	75	75	75	

2.6.2 故障诊断结果

试验使用的深度学习框架为 Google 公司的 Tensorflow^[38]，所用计算机的配置为 CPU i7 6700, 16GB 内存。利用 Python 在 Tensorflow 环境下搭建本章的卷积神经网络模型，模型的数据传递图如图 2-8 所示。训练数据经过模型后，计算出目标函数值，再通过训练模块更新模型中的权值，最后在测试阶段用训练好的模型来对输入信号进行诊断。

利用搭建好的网络对数据集 A、B、C 和 D 进行训练。训练时 Adam 算法的学习率为 0.001，小批量 mini-batch 大小为 256，全连接层使用 Dropout 抑制过拟合，Dropout 率为 0.5。对于数据集 A、B 和 C，训练次数上限 2000 次，对于数据集 D 训练次数上限为 4000 次。由于神经网络的初值是随机的，为了验证每次训练结果的可靠性，对于每个数据集，均训练 20 次，试验结果如图 2-9 所示。

从图中可以看出，卷积神经网络在每一个数据集上的识别率均达到 99%以上。该模型在数据集 C 上的试验结果最高且最为稳定，20 次试验，每一次的识别率均

不低于 99.6%。由试验结果可知，卷积神经网络直接作用在时域的振动信号上，是可行的，并且可以取得很高的识别率。




图 2-8 Tensorflow 环境下生成的卷积神经网络模型




图 2-9 卷积神经网络在 4 个数据集上的识别率

2.7 本章小结

本章提出了对时域信号进行诊断的一维卷积神经网络，介绍了卷积神经网络的基本构成单元，以及结构参数。推导了训练卷积神经网络采用的反向传播公式，以及基于 Adam 优化的训练方法。最后，使用提出的卷积神经网络在 CWRU 滚动轴承数据集上进行训练，训练好的模型的识别率可以达到 99% 以上。

第3章 轴承故障诊断深度卷积神经网络架构

3.1 引言

第二章提出的卷积神经网络模型已经达到了很高的识别率，该模型验证了卷积神经网络直接作用在时域振动信号上的是可行的。由于第二章模型结构简单，可塑性很强，可以从多个角度进行改进。例如，从深度学习角度，加深网络层数，增强表达能力；或者从多尺度角度，引入大小不一样的卷积核，增强卷积核捕提高低频特征的范围。本章将研究如何加深第二章的卷积神经网络的层数，并且减少网络参数个数，进而提高网络的诊断性能。

3.2 WDCNN 算法描述

目前常用的二维卷积神经网络，例如 VGGnet^[39]、ResNet、以及谷歌的 Inception V4^[40]，这三种网络结构均含有堆叠式的 3×3 的卷积核。这样既可以加深网络深度，也可以实现以较少的参数，获取较大的感受野，从而抑制过拟合。然而，对于一维振动信号，两层 3×1 卷积的结构，以 6 个权值为代价，仅仅获取了 5×1 的感受野，反而将上述优势变成了劣势，因此视觉领域的网络结构不适用于轴承故障诊断领域。




图 3-1 WDCNN 结构图

本节针对一维振动信号的特点，设计出名为“第一层宽卷积核深度卷积神经网络” WDCNN（Deep Convolutional Neural Networks with Wide First-layer Kernel）的

模型，其结构特点是第一层为大卷积核，之后卷积层全部为 3×1 的小卷积核。

WDCNN 的第一层为大卷积核，目的是为了提取短时特征，其作用与短时傅里叶变换类似。不同点在于，短时傅里叶变换的窗口函数是正弦函数，而 WDCNN 的第一层大卷积核，是通过优化算法训练得到，其优点是可以自动学习面向诊断的特征，而自动去除对诊断没有帮助的特征。

为了增强 WDCNN 的表达能Ⓒ力，除第一层外，其与卷积层的卷积核大小均为 3×1 。由于卷积核参数少，这样有利于加深网络，同时可以抑制过拟合。每层卷积操作之后均进行批量归一化处理 BN^[40] (Batch Normalization)，然后进行 2×1 的最大值池化，WDCNN 的结构图如图 3-1 所示。

3.3 批量归一化层 (BN)

3.3.1 BN 的正向传播

BN 由谷歌研究员 Sergey Ioffe 提出，其目的是减少内部协变量转移，提高网络的训练效率，增强网络的泛化能力。本文中，将在卷积层与激活层，全连接层与激活层之间加入批量归一化层。其主要操作步骤是将卷积层或全连接层的输入先减去所在 mini-batch 的均值，再除以其标准差，类似于一种标准化操作，因此可以加速训练。但是这样会将输入值限制在一个较窄的区间，降低网络的表达能力。因此，将标准化后的值重新乘以一个缩放量 γ 并加上偏置量 β ，用于增强表达。BN 层的具体运算步骤如下式所示。

当 BN 作用在全连接层时，令第 l 个 BN 层的第 i 个输入为 $y^{l(i)}$ ，批量归一化操作的描述如下式所示：

$$\hat{y}^{l(i)} = \frac{y^{l(i)} - \mu_B}{\sqrt{(\sigma_B^2 + \epsilon)}} \quad (3-1)$$

$$z^{l(i)} = \gamma^{l(i)} \hat{y}^{l(i)} + \beta^{l(i)}$$

$$\mu_B = E_B[y^{l(i)}] = \frac{1}{m} \sum_{k=1}^m y_k^{l(i)} \quad (3-2)$$

$$\sigma_B^2 = \text{Var}[y^{l(i)}] = \frac{1}{m} \sum_{k=1}^m (y_k^{l(i)} - \mu_B)^2$$

式中 $\gamma^{l(i)}$ 、 $\beta^{l(i)}$ ——BN 层的缩放与偏置；

$z^{l(i,j)}$ ——BN 层的输出；

ϵ ——保证数值稳定的常数项。

当 BN 作用在卷积层时，令第 l 个 BN 层的输入为 $\mathbf{y}^l = (y^{l(i,1)}, \dots, y^{l(i,j)}, \dots, y^{l(i,p)})$ ，批量归一化操作的描述如下式所示：

$$\hat{y}^{l(i,j)} = \frac{y^{l(i,j)} - \mu_B}{\sqrt{(\sigma_B^2 + \epsilon)}} \quad (3-3)$$

$$z^{l(i,j)} = \gamma^{l(i)} \hat{y}^{l(i,j)} + \beta^{l(i)}$$

$$\begin{aligned} \mu_B &= E_B[y^{l(i,j)}] = \frac{1}{mp} \sum_{k=1}^m \sum_{j=1}^p y_k^{l(i,j)} \\ \sigma_B^2 &= \text{Var}[y^{l(i,j)}] = \frac{1}{mp} \sum_{k=1}^m \sum_{j=1}^p (y_k^{l(i,j)} - \mu_B)^2 \end{aligned} \quad (3-4)$$

与原文中利用每个 mini-batch 的 μ_B 与 σ_B^2 ，通过无偏估计求解整个训练样本的 μ_{train} 与 σ_{train}^2 不同，本文直接求解整个训练样本的 μ_{train} 与 σ_{train}^2 。在测试时，使用 μ_{train} 与 σ_{train}^2 替换 μ_B 与 σ_B^2 。

3.3.2 BN 的反向求导

与 2.3 节相同，本节将计算全连接层与卷积层的 BN 操作的反向求导过程。当 BN 作用在全连接层时，损失函数 L 关于 BN 层的神经元以及超参数的导数如式 (3-5) 所示：

$$\begin{aligned} \frac{\partial L}{\partial \hat{y}_k^{l(i)}} &= \frac{\partial L}{\partial z_k^{l(i)}} \cdot \gamma^{l(i)} \\ \frac{\partial L}{\partial \sigma_B^2} &= \sum_{k=1}^m \frac{\partial L}{\partial \hat{y}_k^{l(i)}} \cdot (y_k^{l(i)} - \mu_B) \cdot \frac{-1}{2} (\sigma_B^2 + \epsilon)^{-3/2} \\ \frac{\partial L}{\partial \mu_B} &= \left(\sum_{k=1}^m \frac{\partial L}{\partial \hat{y}_k^{l(i)}} \cdot \frac{-1}{\sqrt{(\sigma_B^2 + \epsilon)}} \right) + \frac{\partial L}{\partial \sigma_B^2} \cdot \frac{\sum_{k=1}^m -2(y_k^{l(i)} - \mu_B)}{m} \\ \frac{\partial L}{\partial y_k^{l(i)}} &= \frac{\partial L}{\partial \hat{y}_k^{l(i)}} \cdot \frac{1}{\sqrt{(\sigma_B^2 + \epsilon)}} + \frac{\partial L}{\partial \sigma_B^2} \cdot \frac{2(y_k^{l(i)} - \mu_B)}{m} + \frac{\partial L}{\partial \mu_B} \\ \frac{\partial L}{\partial \gamma^{l(i)}} &= \sum_{k=1}^m \frac{\partial L}{\partial z_k^{l(i)}} \cdot \hat{y}_k^{l(i)} \\ \frac{\partial L}{\partial \beta^{l(i)}} &= \sum_{k=1}^m \frac{\partial L}{\partial z_k^{l(i)}} \end{aligned} \quad (3-5)$$

当 BN 作用在卷积层时，损失函数 L 关于 BN 层的神经元以及超参数的导数如式 (3-6) 所示：

$$\begin{aligned} \frac{\partial L}{\partial \hat{y}_k^{l(i,j)}} &= \frac{\partial L}{\partial z_k^{l(i,j)}} \cdot \gamma^{l(i)} \\ \frac{\partial L}{\partial \sigma_B^2} &= \sum_{k=1}^m \sum_{j=1}^p \frac{\partial L}{\partial \hat{y}_k^{l(i,j)}} \cdot (y_k^{l(i,j)} - \mu_B) \cdot \frac{-1}{2} (\sigma_B^2 + \epsilon)^{-3/2} \\ \frac{\partial L}{\partial \mu_B} &= \left(\sum_{k=1}^m \sum_{j=1}^p \frac{\partial L}{\partial \hat{y}_k^{l(i,j)}} \cdot \frac{-1}{\sqrt{(\sigma_B^2 + \epsilon)}} \right) + \frac{\partial L}{\partial \sigma_B^2} \cdot \frac{\sum_{k=1}^m \sum_{j=1}^p -2(y_k^{l(i,j)} - \mu_B)}{mp} \end{aligned} \quad (3-6)$$

$$\begin{aligned}\frac{\partial L}{\partial y_k^{l(i,j)}} &= \frac{\partial L}{\partial \hat{y}_k^{l(i,j)}} \cdot \frac{1}{\sqrt{(\sigma_B^2 + \epsilon)}} + \frac{\partial L}{\partial \sigma_B^2} \cdot \frac{2(y_k^{l(i,j)} - \mu_B)}{mp} + \frac{\partial L}{mp \partial \mu_B} \\ \frac{\partial L}{\partial \gamma^{l(i)}} &= \sum_{k=1}^m \sum_{j=1}^p \frac{\partial L}{\partial z_k^{l(i,j)}} \cdot \hat{y}_k^{l(i,j)} \\ \frac{\partial L}{\partial \beta^{l(i)}} &= \sum_{k=1}^m \sum_{j=1}^p \frac{\partial L}{\partial z_k^{l(i,j)}}\end{aligned}$$

3.4 WDCNN 超参数设计准则

在 3.2 节，介绍了 WDCNN 的主要结构，本节主要介绍如何基于这个结构进行设计，选取第一层卷积核的大小，步长，以及卷积层的数目。卷积神经网络的设计核心是感受野，即一个神经元在其下层网络中感知范围。如图 3-3 所示，最后一个池化层的神经元，在输入信号中的感受野为输出信号中标记为黑色的神经元。




图 3-3 神经元感受野示意图

由于振动信号是周期性的，且每一个输入信号的相位值不一定相同。为了让 WDCNN 的滤波级学习到位移无关的特征，最后一个池化层的神经元在输入信号中的感受野大小，应当大于一个周期。假设最后一个池化层的神经元在输入的感受野大小为 $R^{(0)}$ ， T 为轴承转动一圈，加速度计记录的数据点数， L 为输入信号长度，那么可以将 $T \leq R^{(0)} \leq L$ 作为 WDCNN 参数选择的准则。以下为设计过程。

首先求解最后一个池化层的神经元，在第 l 个池化层的感受野 $R^{(l)}$ 与在第 $l-1$ 个池化层的感受野 $R^{(l-1)}$ 的关系，如式 (3-7) 所示：

$$R^{(l-1)} = S^{(l)}(P^{(l)}R^{(l)} - 1) + W^{(l)} \quad (3-7)$$

式中 $S^{(l)}$ 、 $W^{(l)}$ ——第 l 个卷积层的步长与卷积核宽度；

$P^{(l)}$ ——第 l 个池化层降采样点的个数；

由于 WDCNN 结构的特殊性，当 $l > 1$ 时， $S^{(l)} = 1$ ， $W^{(l)} = 3$ ， $P^{(l)} = 2$ 。因此

公式 (3-7) 可以简化为式 (3-8):

$$R^{(l-1)} = 2R^{(l)} + 2 \quad (3-8)$$

又因为当 $l=n$ 时, $R^{(n)} = 1$, 其中 n 为卷积层个数。因此, 最后一个池化层的神经元在第 1 个池化层的感受野大小如式 (3-9) 所示:

$$R^{(1)} = 2^{n-1} \times 3 - 2 \quad (3-9)$$

将 (3-9) 代入 (3-7), 得到最后一个池化层的神经元在输入信号上的感受野 $R^{(0)}$ 的表达式如 (3-10) 所示:

$$R^{(0)} = S^{(1)}(P^{(1)}R^{(1)} - 1) + W^{(1)} = 2S^{(1)}(2^{n-1} \times 3 - 2) + W^{(1)} - S^{(1)} \approx S^{(1)}(2^n \times 3 - 4) \quad (3-10)$$

根据 $T \leq R^{(0)} \leq L$ 这一设计准则, 加上 $S^{(1)}$ 必须能够整除 L 这一条件, 可以得到最终的设计准则为

$$T \leq \frac{S^{(1)}(2^n \times 3 - 4)}{S^{(1)}|L} \leq L \quad (3-11)$$

以本文的输入信号为例, 输入信号长度为 $L = 2048$, 信号周期 $T \approx 400$, 如果有 5 层卷积层, 那么第一层卷积层的卷积步长只能为 8 或者 16。在配置其他超参数时, 需要注意, 当增加卷积核的个数, 宽度, 以及网络的层数, 或者减少卷积核的步长, 网络的神经元的总数将会增加, 这可以提高网络的表达能力, 但也存在过拟合的风险。网络的其他超参数需要根据训练数据的多少, 在试验中进一步调整。

3.5 WDCNN 轴承故障诊断试验

3.5.1 WDCNN 试验参数

试验中使用的 WDCNN 模型参数如表 3-2 所示。该 WDCNN 模型共有 5 层卷积与池化层, 第一层卷积核大小为 64×1 , 除第一层外, 其余卷积核的大小均为 3×1 。隐含层神经元个数为 100, Softmax 层共有 10 个输出, 对应 10 种轴承状态。

表 3-2 WDCNN 的结构参数

编号	网络层	卷积核大小/步长	卷积核数目	输出大小(宽度 × 深度)	零补
1	卷积 1	$64 \times 1/16 \times 1$	16	128×16	是
2	池化 1	$2 \times 1/2 \times 1$	16	64×16	否
3	卷积 2	$3 \times 1/1 \times 1$	32	64×32	是
4	池化 2	$2 \times 1/2 \times 1$	32	32×32	否
5	卷积 3	$3 \times 1/1 \times 1$	64	32×64	是
6	池化 3	$2 \times 1/2 \times 1$	64	16×64	否
7	卷积 4	$3 \times 1/1 \times 1$	64	16×64	是
8	池化 4	$2 \times 1/2 \times 1$	64	8×64	否
9	卷积 5	$3 \times 1/1 \times 1$	64	6×64	否
10	池化 5	$2 \times 1/2 \times 1$	64	3×64	否
11	全连接	100	1	100×1	
12	Softmax	10	1	10	

3.5.2 WDCNN 试验模型及训练

Tensorflow 环境下搭建的 WDCNN 模型如图 3-6 a) 所示。将模型的训练模块展开，如图 3-6 b) 所示，可以发现子模块为逆序排列，表示使用 Adam 算法在权重优化时的误差反向传播。




图 3-6 Tensorflow 环境下的 WDCNN 模型细化

WDCNN 模型在训练过程中，识别率以及目标函数值与训练次数的关系曲线分别如图 3-7、3-8 中红线所示。其中图 3-8 纵坐标为对数坐标。为了观察 BN 对 WDCNN 模型的影响，将 WDCNN 模型中所有的 BN 环节去除，重新训练，训练结果如图 3-7 与 3-8 中的蓝线所示。训练时，每个 mini-batch 的大小为 256，Adam 算法的学习率为 0.001。




图 3-7 训练集识别率与训练次数关系图




图 3-8 训练集目标函数值与训练次数关系图

由图 3-7 可以看出，WDCNN 模型大约在 200 次训练后，可以达到 100% 的识别率，而去除 BN 环节后，识别率上升缓慢，且波动很大。由图 3-8 可以看出，除个别节点外，训练样本的目标函数值稳步下降，而去除 BN 环节后，目标函数值下降缓慢，波动较大，在超过 2500 次训练后，训练集的识别率才趋于稳定。训练了 4000 次之后，两者目标函数值相差了近两个数量级。综上，BN 加速了 WDCNN 的训练速度，降低了 WDCNN 模型的训练难度，提高了模型的识别率，是 WDCNN 模型的重要单元。

3.5.3 故障诊断结果

试验中，分别使用样本总量为 90, 120, 300, 900, 1500, 3000, 6000, 12000 和 19800 的训练样本训练 WDCNN 模型，观察数据集增强技术对 WDCNN 诊断能力的影响。由于神经网络的权值初值是随机生成的，为了验证 WDCNN 的稳定性，每个试验重复进行 20 次，试验结果如图 3-9 所示。

由图 3-9 可以看出，当训练样本增加时，识别率逐渐上升，20 次试验标准差逐渐下降，即 WDCNN 的稳定性越来越高。当训练样本数上升到 19800 时，识别

率为 100%，标准差为 0%，而当训练样本数为 90 时，识别率仅为 82%。这充分说明了训练样本个数对 WDCNN 模型诊断性能的巨大影响。此外，当训练样本个数为 900 时，识别率就可以达到 99.35%，WDCNN 模型在使用较少训练数据的情况下，也能达到很高的识别率，模型的抑制过拟合的能力较强。图 3-9 右侧为每种训练样本下，WDCNN 模型诊断一个信号所用时间。由图可知，WDCNN 模型诊断一个信号的时间约为 0.7ms，可以很好满足实时性要求。




图 3-9 不同训练样本数目下，WDCNN 对测试集 D 的识别率与诊断每个信号的时间




图 3-10 训练样本个数为 90, 300, 3000 以及 19800 时，测试样本的特征可视化图

为了深入理解训练数据量对网络训练的影响，通过 *t*-SNE 降维技术，将测试集

在最后一个隐含层的特征降成二维并可视化。图 3-10 分别是训练样本个数为 90, 300, 3000 以及 19800 时, 测试集 D 特征可视化图。从图中可以看出, 随着训练样本的增加, 各类别之间的重叠部分逐渐减少, 并且各类别之间的距离也越来越大, 即特征的可分性也越来越强、表明 WDCNN 对测试样本的判别能力逐渐增强。

3.6 本章小结

本章提出了用于轴承故障诊断的卷积神经网络算法的统一框架: WDCNN 模型。介绍了 WDCNN 的结构, 重点强调了其第一层大卷积核与多层 3×1 的特点。推导了 WDCNN 中的 BN 环节的正向传播与反向求导过程。给出了 WDCNN 模型的超参数的设计准则, 降低了 WDCNN 的调参难度。在 Tensorflow 环境中搭建了 WDCNN 模型进行试验, 在训练样本数为 19800 时, WDCNN 在 CWRU 数据集上取得了 100% 的识别率。

第4章 基于 AdaBN 算法的 WDCNN 轴承故障诊断模型

4.1 引言

在实际的工业应用中,工作环境十分复杂,有两个问题在故障诊断领域值得关注:1)工业现场的噪声无法避免,使用加速度计测得的振动信号易被污染,如何从含有噪声的信号中诊断出轴承的故障成为众多学者研究的重点^[42-44];2)由于工作任务的变化,机器工作负载也会随之改变,如何利用在一个负载下的数据进行训练,对另一个负载下的信号进行诊断,是衡量智能诊断算法适应能力的重要指标^[45,46]。

本章首次将故障诊断中的环境噪声与负载变化造成的信号改变,归结为机器学习中的领域自适应问题^[54],即目标领域(测试样本)的分布与源领域(训练样本)的分布不一致的情况。本章将针对上述两个问题,从领域自适应角度,对 WDCNN 模型进行分析及改进。

4.2 基于 AdaBN 算法的 WDCNN 模型

WDCNN 通过学习训练样本得到网络参数,当测试样本的分布与训练样本的分布差异较大时,WDCNN 模型的诊断性能会下降。为了抑制这种性能衰退,本章将采用 AdaBN^[47](Adaptive Batch Normalization)算法提高 WDCNN 模型的领域自适应能力。

表 4-1 基于 AdaBN 领域自适应的 WDCNN 算法

算法 1 基于 AdaBN 领域自适应的 WDCNN 算法	
输入:	目标领域的信号 p , 在 WDCNN 的 BN 层的第 i 个神经元的表达 $x_t^{(i)}(p) \in \mathbf{x}_t^{(i)}$, 其中 $\mathbf{x}_t^{(i)} = \{x_t^{(i)}(1), \dots, x_t^{(i)}(n)\}$, 对第 i 个神经元, 已训练好的缩放与平移参数 $\gamma_s^{(i)}$ 和 $\beta_s^{(i)}$
输出:	调整后的 WDCNN 网络
For	目标领域内每个神经元 i 和每个信号 p
	计算目标领域中所有样本的均值和方差:
	$\mu_t^{(i)} \leftarrow \mathbf{E}[\mathbf{x}_t^{(i)}]$
	$\sigma_t^{(i)} \leftarrow \mathbf{Var}[\mathbf{x}_t^{(i)}]$
	计算 BN 层的输出:
	$\hat{\mathbf{x}}_t^{(i)}(p) = \frac{x_t^{(i)}(p) - \mu_t^{(i)}}{\sigma_t^{(i)}}$
	$\mathbf{y}_t^{(i)}(p) = \gamma_s^{(i)} \hat{\mathbf{x}}_t^{(i)}(p) + \beta_s^{(i)}$
End for	

AdaBN 算法, 是基于 BN 的领域自适应算法, 主要用于图像识别领域。该算

法使用目标领域样本在每一个 BN 层的 μ_t 与 σ_t^2 ，替换原来 BN 层所使用的由源领域样本计算出的 μ_s 与 σ_s^2 。由于 BN 可以减少内部协变量，通过 BN 对源领域样本的作用，以及 AdaBN 对目标领域样本的作用，可以源领域与目标领域调整到一个新的分布空间，在此空间内，两者近似一致，从而达到领域自适应的目的。因为 WDCNN 算法采用了 BN 算法，所以可以使用 AdaBN 算法来提高 WDCNN 模型的领域自适应能力，进而增强 WDCNN 模型在噪声以及负载变化的情况下的适应能力。基于 AdaBN 领域自适应的 WDCNN 算法的具体描述如表 4-1 所示。

基于 AdaBN 的 WDCNN 算法的框架图如图 4-1 所示。首先使用训练样本训练 WDCNN 模型，直至训练完成。如果训练信号与测试信号的领域分布不一致，将测试集输入到 WDCNN 模型，只进行数据正向传播，将所有 BN 层的均值方差用测试集的均值方差替换，其他网络参数保持不变。至此，领域自适应过程结束，可以利用改进后的模型对测试集的每一个样本进行诊断。




图 4-1 基于 AdaBN 领域自适应的 WDCNN 算法流程图

4.3 噪声环境下轴承故障诊断性能分析

本节将分析基于 AdaBN 算法的 WDCNN 模型的抗噪能力。首先，给测试样本添加噪声，模拟工业环境的噪声污染。被诊断信号的噪声一般为加性高斯白噪声^[48]，因此，本文将对测试集的信号加上不同程度的加性高斯白噪声，用来检测训练 WDCNN（AdaBN）模型的抗噪性能。

4.3.1 噪声信号准备

评价信号中噪声强弱的标准是信噪比 SNR（Signal to Noise Ratio）。令 P_{signal} 与 P_{noise} 分别表示信号与噪声的能量，则 SNR 公式如式（4-1）所示。信号中所含噪声越多，SNR 值就越小。当 SNR 值为 0dB 时，信号与噪声所含能量相等。

$$\text{SNR}_{\text{dB}} = 10 \log_{10} \left(\frac{P_{\text{signal}}}{P_{\text{noise}}} \right) \quad (4-1)$$

如图 4-2 所示, 由上至下分别展示了未加噪声的轴承内圈故障信号, 加性高斯白噪声信号, 以及两者相加后带有噪声的内圈故障信号。图中带噪声信号的信噪比 $\text{SNR}=0\text{dB}$, 可以看出, 信号被噪声严重污染, 人眼几乎无法辨析出原型号的振动特征。因此, 从带有噪声的信号中提取出有效的故障信息, 难度很大。




图 4-2 内圈故障信号, 加性高斯白噪声以及两者相加后 $\text{SNR}=0\text{dB}$ 的信号

4.3.2 第一层卷积核大小对抗噪性影响

为了验证 WDCNN 模型及其 AdaBN 领域自适应处理后的抗噪性能, 本节将测试其在 SNR 值从 -4dB 到 10dB 的环境下的识别率。同时, 为了验证 WDCNN 模型中第一层大卷积核的必要性, 试验也测试了当第一层卷积核大小从 16 到 128 变化时, WDCNN 及 WDCNN (AdaBN) 在不同强度带噪声信号上的诊断率。

试验结果如表 4-2 与 4-3 所示。由表 4-2 可知, 在低 SNR 的环境中, 卷积核较大时, WDCNN 的识别率较高。例如, 当第一层卷积核大小为 112×1 时, WDCNN 模型在 $\text{SNR}=0\text{dB}$ 时的诊断率可以达到 90% 以上, 而当卷积核大小为 16×1 时, 其诊断率仅为 55.37%, 两者差距很大。此外, 第一层卷积核并不是越大越好, 当卷积核为 128×1 时, 在 $\text{SNR} < 0\text{dB}$ 的场景下, 其诊断率均小于 96×1 的卷积核。根据以上观察推断, 当卷积核过小时, 难以捕捉到中低频的特征, 容易受高频噪声干扰; 而当卷积核很大时, 时域分辨率降低, 造成部分细节特征的缺失, 使诊断率不升反降。因此, 选择合适的第一层卷积核对 WDCNN 模型的抗噪性能有较大的影响。本文的经验是, 当噪声较大时应选取较大的卷积核, 卷积核宽度建议不小于 3 倍步长。

由表 4-3 可知, AdaBN 算法大幅提高了 WDCNN 模型的识别率。WDCNN (AdaBN) 模型在 $\text{SNR} \geq -4\text{dB}$ 时的识别率均超过 90%, 其中对 $\text{SNR}=-4\text{dB}$ 样本的识别率比 WDCNN 模型提高了 25% 左右。此外, 当卷积核较小时, 其识别率也比改进前的识别率有大幅提升。例如当 $\text{SNR}=-4\text{dB}$ 时, 卷积核大小为 64×1 的 WDCNN

模型，前后诊断率相差了 40%之多。

表 4-2 WDCNN 在不同噪声环境下的诊断率

卷积核大小	SNR (dB)							
	-4	-2	0	2	4	6	8	10
16	27.14%	40.89%	55.37%	72.03%	85.71%	94.58%	98.41%	99.35%
24	35.32%	52.72%	70.15%	84.75%	94.37%	98.50%	99.64%	99.82%
32	42.00%	57.66%	72.76%	86.53%	95.47%	98.40%	99.52%	99.69%
40	46.84%	63.03%	77.55%	90.20%	97.07%	99.21%	99.71%	99.82%
48	50.15%	66.16%	80.21%	92.08%	97.69%	99.35%	99.73%	99.87%
56	51.67%	66.83%	80.85%	92.32%	97.84%	99.21%	99.73%	99.79%
64	51.75%	67.15%	82.03%	93.06%	98.07%	99.29%	99.79%	99.81%
72	53.69%	68.53%	82.23%	92.93%	97.91%	99.35%	99.71%	99.82%
80	56.07%	69.39%	84.24%	94.84%	98.69%	99.44%	99.83%	99.85%
88	56.05%	71.62%	85.33%	95.04%	98.46%	99.37%	99.74%	99.83%
96	64.29%	78.80%	89.91%	96.97%	99.03%	99.62%	99.81%	99.85%
104	62.91%	79.21%	90.36%	97.52%	99.23%	99.77%	99.81%	99.84%
112	66.95%	80.81%	90.51%	97.01%	98.88%	99.54%	99.83%	99.81%
120	61.84%	77.60%	90.47%	97.40%	99.08%	99.67%	99.81%	99.87%
128	60.88%	77.49%	89.79%	97.28%	99.13%	99.59%	99.83%	99.83%
最大	66.95%	80.81%	90.51%	97.52%	99.23%	99.77%	99.83%	99.87%

表 4-3 基于 AdaBN 领域自适应的 WDCNN 算法在不同噪声环境下的诊断率

卷积核大小	SNR (dB)							
	-4	-2	0	2	4	6	8	10
16	81.84%	90.38%	95.66%	98.45%	99.01%	99.54%	99.75%	99.77%
24	87.24%	93.99%	97.34%	99.03%	99.61%	99.81%	99.87%	99.89%
32	89.81%	95.16%	97.93%	99.29%	99.55%	99.76%	99.77%	99.86%
40	90.96%	95.99%	98.32%	99.33%	99.59%	99.75%	99.83%	99.89%
48	91.69%	96.29%	98.33%	99.39%	99.67%	99.80%	99.81%	99.88%
56	92.65%	96.59%	98.61%	99.47%	99.70%	99.77%	99.86%	99.87%
64	92.56%	96.79%	98.77%	99.49%	99.67%	99.83%	99.87%	99.93%
72	92.36%	96.39%	98.51%	99.35%	99.61%	99.76%	99.79%	99.84%
80	92.31%	96.70%	98.67%	99.40%	99.62%	99.76%	99.87%	99.86%
88	92.61%	97.02%	98.77%	99.45%	99.63%	99.75%	99.81%	99.83%
96	92.65%	97.04%	98.77%	99.57%	99.67%	99.80%	99.83%	99.84%
104	92.45%	96.57%	98.63%	99.51%	99.67%	99.79%	99.81%	99.91%
112	91.70%	96.31%	98.68%	99.43%	99.67%	99.79%	99.89%	99.91%
120	92.11%	96.46%	98.75%	99.47%	99.66%	99.77%	99.83%	99.89%
128	91.92%	96.53%	98.67%	99.38%	99.63%	99.73%	99.82%	99.87%
最大	92.65%	97.04%	98.77%	99.57%	99.70%	99.83%	99.89%	99.93%

4.3.3 抗噪性比较

本节将比较 WDCNN (AdaBN) 模型与常见的 FFT-SVM 与 FFT-MLP 模型，以及当下最具代表性的深度 FFT-DNN 模型^[26]之间的性能差异。其中 SVM 使用径向基核函数，DNN 每层神经元个数分别为 1025, 500, 200, 100 和 10，WDCNN 模型的第一层卷积核大小为 112×1 。

试验结果如图 4-3 所示，可以看出，FFT-DNN 虽然诊断结果优于 FFT-MLP，

但两者的抗噪性都很弱，例如在噪声较弱的 $\text{SNR}=4\text{dB}$ 的环境中，两个模型的识别率均不足 90%。相比之下，同样是神经网络模型的 WDCNN 算法的抗噪性明显高于前两个。虽然，WDCNN 模型的诊断率比 FFT-SVM 稍低，经过 AdaBN 算法改进后，WDCNN 模型的诊断率明显高于其它算法。综上，基于 AdaBN 的 WDCNN 模型具有很强的抗噪性。




图 4-3 WDCNN(AdaBN)在不同噪声环境下与其它算法的诊断率对比

4.4 变载情况下故障诊断性能分析

4.4.1 变载问题描述

工作负载的变化对一个机械系统很常见，当负载发生变化后，由传感器测得的信号也会发生变化。图 4-4 为不同负载下，归一化后内圈缺陷大小为 0.014inch 的诊断信号。由图 4-4 可知，不同负载下，振动信号中特征的个数不相同，幅值大小也不一致，波动周期与相位差别也很大。以上情况会造成分类器对提取的特征无法进行正确归类，从而降低智能诊断系统的识别率。




图 4-4 不同负载下，归一化后内圈缺陷大小为 0.014inch 的诊断信号

因此,使用在一种负载下的数据训练好的机器学习模型,对负载变化时的振动信号进行故障诊断,具有很重要的实际意义。本节中,将分别使用负载为 1hp、2hp 与 3hp 下的振动信号对 WDCNN (AdaBN) 模型进行训练,使用其余两种负载下的信号作为测试集进行测试。变负载自适应问题的具体描述如表 4-4 所示。

表 4-4 变负载自适应问题描述

目标: 使用源领域信号训练, 诊断目标领域的信号			
域类型	源领域	目标领域	
描述	一种负载下带标签信号	另一种负载下无标签信号	
数据集	训练集 A	测试集 B	测试集 C
	训练集 B	测试集 C	测试集 A
	训练集 C	测试集 A	测试集 B

4.4.2 试验结果与分析

试验结果如图 4-5 所示, FFT-SVM 算法的平均诊断率低于 70%, FFT-MLP 和 FFT-DNN 能实现约 80% 的识别率, 而 WDCNN 可以达到 90% 平均识别率。此外, 使用 AdaBN 算法, 可以将 WDCNN 模型的识别率可以提高到 95.9%。特别是从当使用训练集 B (负载为 2hp) 来训练分类器, 对测试集 A (负载为 1hp) 进行诊断时, FFT-SVM、FFT-MLP、FFT-DNN 模型的识别率比 WDCNN 的识别率低超过了 20%。以上结果表明, 相比于传统的智能诊断算法与当下流行的深度学习算法, WDCNN 模型的跨负载领域自适应能力很强。此外, 结合 4.3 节也可以看出, FFT-SVM 的抗噪性很强, 但跨负载领域自适应性很差, FFT-MLP 与 FFT-DNN 模型的抗噪性很弱, 但跨负载领域自适应性很强, 这说明这几种算法很难适应多变的环境。相比之下, 基于 AdaBN 的 WDCNN 模型, 甚至是 WDCNN 模型同时具有很强的抗噪性能与跨负载领域自适应能力, 可以适应多变的工作环境。

从图 4-5 中可以看出, AdaBN 算法将 WDCNN 模型的诊断率提高了近 6%。特别是在训练集 C 上进行训练, 在测试集 A 或 B 上进行诊断, 识别率被提高超过 10%。为了研究 AdaBN 提高 WDCNN 的识别率的原因, 下面的试验中, 先使用训练集 C 训练 WDCNN 模型, 将测试集 B 与 C 分别输入到 WDCNN 模型中, 分别提取两个数据集在最后一个隐含层的特征表达。使用 t -SNE^[49] 将上述特征降成二维, 可视化后的特征分布图如图 4-6 (a) 所示。再使用 AdaBN 算法改进 WDCNN 模型, 重复上述降维可视化过程, 测试集 B 与 C 的特征表达如图 4-6 (b) 所示。

由图 4-6 (a) 可以看出, 测试集 B 在 WDCNN 的最后一个隐含层特征表达的可分性很强, 但其分布与测试集 C 不一致, 导致分类器分类错误。而根据图 4-6 (b), 在经过 AdaBN 领域自适应后, 测试集 B 和测试集 C 的特征表达点基本重合, 表明两者的分布几乎一致, 因此模型可以很好地分类。综上, AdaBN 算法通过将目标领域与源领域的特征分布调整到一致, 很好的提高 WDCNN 模型的变负

载自适应能力。




图 4-5 WDCNN 算法及对照算法在 6 种不同域自适应场景中的识别率




图 4-6 测试集 C 和 B 在用训练集 C 训练好的 WDCNN 模型上，最后一个隐含层的 t -SNE 的表达，其中 a) 没有 AdaBN，b) 使用 AdaBN。

4.5 WDCNN 模型可视化分析

为了更好地理解 WDCNN 模型，本节利用可视化技术，探究 WDCNN 高性能的原因。

4.5.1 第一层卷积核可视化

本节可视化 WDCNN 第一层 16 个卷积核，如图 4-7 所示。图 4-7 a) 为第一层

卷积核大小的可视化，图 4-7 b) 为第一层卷积核在频域上的表达（使用了快速傅里叶变换）。从时域波形中可以看出，学习得到的波形差异较大，其中第 6 个与第 11 个卷积核（自上而下，从左到右）的形状与正弦函数相似且周期较大，可以看出这两个卷积核提取的是被卷积区域的低频特征。由频域表达可以看出，大多数卷积核频域的峰值集中在中频段，部分在低频段。以上观察表明，卷积核提取的是中低频特征，因此，第一层卷积核可以看成是一个低通滤波器，这将有利于模型在噪声环境下的诊断。此外，卷积核每次只提取几个频域特征，且提取位置相对集中，对比 FFT 提取所有频段的特征，使用卷积核进行特征提取的方式显得更加具有针对性，也更加高效。




图 4-7 WDCNN 第一层卷积核可视化：a) 第一层卷积核，b) 频域上的表达

4.5.2 神经元可视化

本节将可视化样本在 WDCNN 模型上的神经元表达。10 种状态的轴承故障信号，在 WDCNN 第一个卷积层神经元激活表达如图 4-8 所示。




图 4-8 10 种故障类型在第一个卷积层的神经元表达，红色为最大激活，蓝色为未激活

图中，蓝色表示神经元没有激活，红色表示神经元被最大激活。由图可以看出，经过卷积操作后，不同类别的信号，激活 WDCNN 第一个卷积层的神经元个数与

位置也不相同。其中，没有故障的振动信号神经元表达以蓝色为主，这表明其被激活的神经元个数较少。




图 4-9 正常信号与两段缺陷大小为 0.014inch 的内圈故障信号，在所有卷积层以及全连接层神经元表达

图 4-9 可视化了被诊断信号在所有卷积激活层以及全连接激活层的神经元表达。其中，图 4-9 (a) 为无缺陷信号的表达，4.9 (b) 与 4.9 (c) 均为缺陷大小为 0.014inch 的内圈故障信号的表达，但两段信号特征位置及个数不一致。由图 4-9 (a) 与 4.9 (b) 可以看出，随着卷积层的增加，两种信号表达的区分度越来越明显，在第 5 层的表达可以清晰看出两者的不同。从图 4-9(b)与 4.9(c)被红色方框标记的位置可以看出，在原始信号中变化明显的特征在神经网络中得以保留。比较 4.9(b)与图 4-9(c)，两者在前几个卷积层，被激活的区域的位置不相同，但随着层数的增加，被激活的位置逐渐趋于一致，这展示了 WDCNN 获取位置无关的特征的

过程，印证了 WDCNN 强大的特征提取能力。

4.5.3 分类过程可视化

本节可视化了测试集 D 所有样本，在所有卷积层与全连接层的特征表达经过 t -SNE 降成 2 维后的分布，如图 4-10 所示。有两点值得注意：1) 经过第一层卷积操作之后，正常信号与其它信号已经可以很好的区分，这表明 WDCNN 区分有故障信号与没有故障信号的能力很强；2) 从第二个卷积层的表达可以看出，第 6 类与第 10 类故障在该层的特征表达线性不可分，但随着层数的增加，到第四层卷积层时，两类故障的特征表达线性可分，这说明随着层数的增加，WDCNN 模型的非线性表达能力在增强。综上，WDCNN 通过加深卷积神经网络的层数，将不可分的特征映射到非线性可分空间，也验证了 WDCNN 模型加深网络层数的设计思想的合理性。




图 4-10 测试集 D 所有样本在所有卷积层与全连接层表达经过 t -SNE 可视化之后的分布图

4.6 本章小结

本章提出了基于 AdaBN 算法的 WDCNN 模型。首次将工作噪声与负载变化对传感信号带了干扰的问题，统一归结为领域自适应问题。给出了 AdaBN 算法的具体步骤，以及与 WDCNN 模型的结合方式。分析了该算法的抗噪性能，并且验证了 WDCNN 模型第一层大卷积核的必要性。试验验证了 WDCNN 以及 WDCNN (AdaBN) 算法的具有很高变负载自适应性能。通过模型可视化技术，进一步分析了 WDCNN 高性能的原因。

第5章 基于训练干扰的 WDCNN 轴承故障诊断模型

5.1 引言

虽然 AdaBN 算法可以提高 WDCNN 模型的抗噪能力与变载领域自适应能力,但 AdaBN 算法需要整个测试集的样本在 WDCNN 每一个 BN 层的均值与方差,这对于一个故障诊断系统,在初期是难以满足的。解决这个问题有两个思路:1) 根据部分测试样本的均值方差,对整体测试样本的均值方差进行估计^[45];2) 不获取任何测试集的信息,通过对 WDCNN 模型本身结构与训练方式进行改进,增强其泛化能力。

本章将对 WDCNN 进行改进,提出了一个新的网络,名为基于训练干扰的卷积神经网络 TICNN (Convolutional Neural Network with Training Interference)。该模型在训练时对模型添加干扰,使训练好的模型在测试信号发生变化时,能可以保持高识别率。

5.2 TICNN 模型

5.2.1 TICNN 模型结构

TICNN 模型的结构与 WDCNN 类似,第一层卷积核均为大卷积核,大小为 64×1 ,之后的卷积核均为 3×1 的小卷积核。两者结构上两点不同:1) TICNN 模型的第一个卷积层的步长从 16 减少到了 8,这样做增加了 TICNN 模型在时域上的分辨率;2) TICNN 增加了一个卷积层与池化层,这样做可以增强网络的非线性表达能力。具体的模型参数如表 5-1 所示,其中第六个卷积层在卷积时没有采用零补,其余的卷积操作均采用零补。此外,第一个卷积层的输出神经元的个数为 4096,大于原始信号的长度 2048,表明第一个卷积层的特征是原始信号的过完备表达。

TICNN 模型的结构图如图 5-1 所示。在使用第一层大卷积核进行卷积时,先对卷积核进行 Dropout 操作,这是 TICNN 模型的第一个训练干扰,目的是给 TICNN 训练时提供不完整的信号,从而强化 TICNN 在信号部分缺失时的诊断能力。

TICNN 模型的训练流程图如 5.2 a) 所示。可以看出, TICNN 使用了极小的 mini-batch 来进行批量训练,这是 TICNN 模型的第二个训练干扰,目的是增大 mini-batch 的均值方差变化范围增加,增强模型对测试集的均值方差于训练集发生的偏移时容忍度。

在测试阶段,如图 5-2 b) 所示,采用集成学习的方式 (Ensemble Learning) 来进行预测。文中采用的是多数同意规则 (Majority Voting),即独立训练 5 个 TICNN 模型,对于同一个测试样本,采用投票的方式来决定信号所属故障。集成学习被用

来提高模型的识别率，增强模型的稳定性。

表 5-1 TICNN 的结构参数

编号	网络层	核大小/步长	核数目	输出大小(宽度 × 深度)	零补
1	卷积 1	$64 \times 1/16 \times 1$	16	256×16	是
2	池化 1	$2 \times 1/2 \times 1$	16	128×16	否
3	卷积 2	$3 \times 1/1 \times 1$	32	128×32	是
4	池化 2	$2 \times 1/2 \times 1$	32	64×32	否
5	卷积 3	$3 \times 1/1 \times 1$	64	64×64	是
6	池化 3	$2 \times 1/2 \times 1$	64	32×64	否
7	卷积 4	$3 \times 1/1 \times 1$	64	32×64	是
8	池化 4	$2 \times 1/2 \times 1$	64	16×64	否
9	卷积 5	$3 \times 1/1 \times 1$	64	16×64	是
10	池化 5	$2 \times 1/2 \times 1$	64	8×64	否
11	卷积 6	$3 \times 1/1 \times 1$	64	6×64	否
12	池化 6	$2 \times 1/2 \times 1$	64	3×64	否
13	全连接	100	1	100×1	
14	Softmax	10	1	10	




图 5-1 TICNN 模型

5.2.2 卷积核 Dropout 算法

Dropout 由多伦多大学的 Srivastava 等^[50]提出，可以抑制神经网络过拟合，提高网络的泛化性能。Dropout 算法是以概率 p ，将一层神经网络中的神经元的值置零，从而阻止同层神经元之间的相互适应（Co-adapting）。因此，Dropout 使神经元的特征表达更加的独立，可以提高网络的表达能力。

通常情况下，Dropout 用于全连接层，因为全连接层占整个卷积神经网络的参数比重最大。但在本文中，将 Dropout 用在第一层卷积核。当卷积核被随机置零，可以看做是给被卷积区域引入了噪声。为了模拟噪声的多样性与不确定性，TICNN

采用变化的 Dropout 率，在每一次进行 mini-batch 训练时，Dropout 率服从 0.1 到 0.9 的均匀分布。为了避免 TICNN 因为训练时添加的噪声过多，对正常样本的识别率会降低的情况，每 5 次训练中都将 Dropout 率置为 1，即将卷积核置零。




图 5-2 a)TICNN 模型的训练过程流程图，b)TICNN 模型的测试过程流程图

提出的卷积核 Dropout 方法如公式 (5-1) 与图 5-2 所示。Dropout 率 p 服从均匀分布 $U(0.1,0.9)$ ；控制第 i 个卷积核中第 k 个权值是否被激活的开关 $\mathbf{r}_i^1(k)$ ，服从概率为 p 的伯努利分布； $\tilde{\mathbf{K}}_i^1$ 表示经过 Dropout 运算后的卷积核的权值，其中需要注意的是，不同于 Dropout 原文，本文中的卷积核在训练时就除以 p ，而不是在测试时所有卷积核乘以 p 。因为文中的 Dropout 率是变化的，若按照 Dropout 原文中给出的方法，将无法进行变 Dropout 率的运算。

$$\begin{aligned}
 p &\sim \text{Uniform}(0.1,0.9) \\
 \mathbf{r}_i^1(k) &\sim \text{Bernoulli}(p) \\
 \tilde{\mathbf{K}}_i^1 &= \frac{\mathbf{r}_i^1 * \mathbf{K}_i^1}{p} \\
 \mathbf{z}_i^1(j) &= \tilde{\mathbf{K}}_i^1 * \mathbf{x}_j^1
 \end{aligned} \tag{5-1}$$

因为增加了第一层卷积核 Dropout，在训练 TICNN 模型时，目标函数 L 对第一层卷积核的导数也会有所改变。由 2.3.3 节的反向传播公式，在 $\frac{\partial L}{\partial y_k^{(i,j)}}$ 已知的基础上，利用链式求导法则，目标函数 L 对第一层与其它层卷积核权值偏导公式为：

$$\begin{cases} \frac{\partial L}{\partial \mathbf{K}_i^l(j')} = \sum_{k=1}^m \sum_j \left(\frac{\mathbf{x}^{l(j)}}{p} \right) * \left(\frac{\partial L}{\partial y_k^{l(i,j)}} \right), l=1 \\ \frac{\partial H}{\partial \mathbf{K}_i^l(j')} = \sum_{k=1}^m \sum_j \left(\mathbf{x}^{l(j)} \right) * \left(\frac{\partial L}{\partial y_k^{l(i,j)}} \right), l>1 \end{cases} \quad (5-2)$$




图 5-3 卷积核 Dropout 示意图 a)无 Dropout, b)有 Dropout

5.2.3 极小批量训练

美国东北大学 Keskar 等人证明, 使用更小的 mini-batch 训练神经网络, 有利于增加模型的泛化性能^[51]。Keskar 推荐的 mini-batch 大小为 32、64 到 512, 本文中使用的 mini-batch 大小更小, 仅为样本种类的个数 10。3.3 节中已经介绍了 BN 操作需要减去 mini-batch 在每一个神经元的均值并除以标准差, 在测试时, 使用全体训练样的均值方差来代替 mini-batch。4.2 节介绍了使用测试集的均值方差来代替训练集的均值方差的 AdaBN 算法, 用来提高网络的领域自适应能力。但是, 在实际工程中, 获取全体测试集的均值方差很难实现。本文的想法是训练一个在 BN 层中均值方差发生改变时, 依然可以进行高识别率分类的模型。基于这个想法, 在每一次 mini-batch 训练时, 可以使 BN 层的均值方差应尽可能的不一致, 而极小 mini-batch 训练正好可以满足这一要求。

令传到 BN 层的一个 p 维 mini-batch 的输入为: $\mathbf{y}^l = (y^{l(i,1)}, \dots, y^{l(i,p)})$, $y^{l(i,j)}$ 的期望值为 $E[y^{l(i,j)}] = \frac{1}{p|b|} \sum_{k=1}^{|b|} \sum_{j=1}^p y_k^{l(i,j)}$ 。对于两个 mini-batch b_1, b_2 , 如果 $|b_1| \gg |b_2|$, 根据中心极限定理, $\text{Var}(E[y^{l(i,j)}])_{b_2} < \text{Var}(E[y^{l(i,j)}])_{b_1}$ 。这表明, 在训练过程中, 当 mini-batch 中包含的样本数目越少, 其均值的波动范围也就越大, 也就越满足给训练模型的均值方差带来干扰的要求。此外, 为了使均值方差不出现与整体训练样本过大的偏离, 至少应该保证 mini-batch 的大小不小于需要分类的数量, 否则 mini-batch 在 BN 层的均值方差将始终偏离整体的均值方差, 不利于模型的训练。

使用极小的 mini-batch 进行训练时, 并不会给 TICNN 训练过程带来过多的困

难。令 $L_i(x)$ 第 k 个 mini-batch 输入 x_i 的损失函数，为了最小化损失函数，假设采用的是随机梯度速降方法。迭代算法如式(5-3)所示，当 mini-batch 的大小 $|b_k|$ 下降时，对训练带来的影响与学习率 α_k 上升带来的影响相同。对于使用 BN 的模型， α_k 可以比普通模型 1 到 2 个量级^[41]，因此，使用极小 mini-batch 训练不会对模型的训练带来过多的困难。

$$\begin{aligned} \min_{x \in \mathbb{R}^n} L(x, \theta) &:= \frac{1}{|b_k|} \sum_{i=1}^{|b_k|} L(x_i, \theta) \\ \theta_{k+1} &= \theta_k - \alpha_k \left(\frac{1}{|b_k|} \sum_{i=1}^{|b_k|} \nabla L(x_i, \theta) \right) \end{aligned} \quad (5-3)$$

5.2.4 基于多数同意规则的集成学习

本章采用多数同意规则^[52]来减少神经网络随机初始化带来的不利影响，进而提高 TICNN 模型的稳定性与精度。多数同意规则仅仅对标签进行操作，假设 $d_{i,j}$ 为第 i 个分类器对第 j 个测试样本的投票结果。对于 n 类的多分类问题， $d_{i,j}$ 是为只有一个值为 1，其余值为 0 的一个矩阵，值为 1 表示第 i 个分类器选择了第 j 个测试样本，反之亦然。假设有 T 个分类器，如果有一类得到了超过一半分类器的投票，则将这个结果作为最后的诊断结果，如果没有一种类别得到了超过一半的投票，那么将不给出结果。多数同意规则的流程图如图 5-4 所示。




图 5-4 多数同意规则流程图

多分类规则的公式如式(5-4)所示

$$H(x) = \begin{cases} c_j & \text{if } \sum_{i=1}^T d_i^j(x) > \frac{1}{2} \sum_{k=1}^l \sum_{i=1}^T d_i^k(x) \\ \text{rejection} & \text{otherwise} \end{cases} \quad (5-4)$$

在分类器的输出相互独立的条件下，理论上可以证明，多数同意规则可以提升分类器的性能。对于有 T 个子分类器的 n 类多分类问题，假设每一个分类器做出一个正确诊断的概率为 p ，那么获得至少 $[T/2 + 1]$ 个分类器正确投票的概率是：

$$P_{ens} = \sum_{k=(\frac{T}{2})+1}^T \binom{T}{k} p^k (1-p)^{T-k} \quad (5-5)$$

可以看出, 如果 $p > 0.5$, $T \rightarrow \infty$, 那么 $p_{ens} \rightarrow 1$ 。

需要注意的是, 每个分类器的识别率 $p > 0.5$ 是多数同意规则的必要条件, 否则集成之后模型的性能不升反降。并且, 以上公式的推导都是基于分类器相互独立这一假设, 但实际中, 分类器不可能做到相互独立, 尤其是使用相同的模型。所以通常情况只会看到分类器的性能有所提高, 但不会提高很多。

5.3 TICNN 模型训练过程

Tensorflow 环境下, TICNN 模型与 WDCNN 模型十分相似, 不同之处在于, TICNN 模型比 WDCNN 多了一个卷积层以及池化层, 故本节不再展示 TICNN 整体结构。Tensorflow 环境下 TICNN 第一个卷积层的展开图如图 5-5 所示。可以看出, 卷积核 (kernels) 对数据进行卷积之前, 先进行了 Dropout 运算, 这与 5.2.2 节的卷积核 Dropout 环节对应。




图 5-5 Tensorflow 环境下 TICNN 第一个卷积层的展开图

TICNN 由于 mini-batch 的大小仅为 10, 为了充分训练网络, TICNN 模型的训练次数为 50000 次, Adam 优化算法的学习率为 0.001。模型对整个训练集的识别率以及目标函数值与训练次数的关系曲线分别如图 5-6、5.7 所示, 其中图 5-7 纵坐标为对数坐标。由图 5-6 可以看出, 当训练次数达到 5000 次时, TICNN 对训练集的识别率趋于稳定, 接近 100%。与 WDCNN 不同, 训练集在 TICNN 上的目标函数值随着训练次数的增加, 在前 20000 次内波动下降, 而在后 30000 次下降幅度

不大，尤其是在 25000 次到 30000 次之间，相对波动较大，最后在接近 50000 次时趋于平稳，目标函数的量级接近 10^{-4} 。可以看出，相比 WDCNN，TICNN 更难训练。




图 5-6 训练集 D 训练 TICNN 时识别率与训练次数关系图




图 5-7 训练集 D 训练 TICNN 时目标函数值与训练次数关系图

由于 TICNN 模型的核心技术是两个训练干扰，为了观察训练干扰在训练过程中对模型的影响，图 5-8 展示了 TICNN 模型与 WDCNN 模型的第一层卷积核权值分布随着训练次数的变化图。需要注意的是，WDCNN 模型的 mini-batch 大小为 256，训练了 4000 次，则训练的数据总量约为 102 万，而 TICNN 虽然训练了 50000 次，但由于 mini-batch 大小仅为 10，训练的数据总量仅为 50 万，所以 TICNN 总体训练数据要少于 WDCNN。可以看出，TICNN 的第一层卷积核随着训练次数的增加，权值分布范围逐渐扩大，而 WDCNN 第一层卷积核权值分布的范围几乎没有发生变化。可以推断，TICNN 模型的干扰改变了第一层卷积核的权值大小的分布，而 WDCNN 模型主要改变了卷积核的波形，但是并未改变权值分布。




图 5-8 TICNN 模型与 WDCNN 模型的第一层卷积核权值分布随着训练次数的变化图

5.4 TICNN 抗噪性分析

本节将研究 TICNN 模型的抗噪能力，试验所使用的训练样本为表 3-1 中的训练集 D，测试样本为加上了不同程度加性高斯噪声的测试集 D，详细说明参考 4.3 节。

5.4.1 Mini-batch 大小对 TICNN 抗噪性能的影响

本节测试在不同大小的 mini-batch 训练下，具有 5 个 TICNN 的集成模型对带噪声的测试集的认识率。每一种 mini-batch 大小均进行了 20 试验，试验结果如表 5-2 所示。

表 5-2 不同大小的 minibatch 下，TICNN 对噪声信号的识别率

SNR(dB)	mini-batch 大小					
	100	50	40	30	20	10
10	99.71±0.18	99.75±0.06	99.77±0.07	99.69±0.08	99.69±0.12	99.63±0.06
8	99.71±0.17	99.69±0.11	99.59±0.10	99.70±0.10	99.71±0.13	99.75±0.08
6	99.64±0.17	99.64±0.14	99.53±0.09	99.66±0.11	99.61±0.14	99.59±0.08
4	99.48±0.21	99.52±0.13	99.51±0.14	99.61±0.09	99.57±0.09	99.61±0.18
2	98.87±0.33	98.99±0.20	99.17±0.23	99.31±0.12	99.11±0.12	99.27±0.16
0	96.04±0.51	96.96±0.50	97.62±0.47	97.91±0.40	98.11±0.33	98.22±0.27
-2	88.39±1.21	91.25±1.16	92.71±1.20	93.85±1.02	95.55±1.08	96.47±0.34
-4	68.29±2.79	74.10±1.38	76.69±2.24	80.35±2.97	81.68±1.63	82.05±0.66

由表 5-2 可以看出：

- 1) 当 mini-batch 大小为 100 时，TICNN 可以对噪声较小的测试集取得很高的识别率，但随着信号噪声的增加，识别率下降的最快；
- 2) 当 mini-batch 取很小值时，TICNN 模型的抗噪能力明显提升，特别是当 mini-batch 大小为 10 时，在噪声很大时，依然取得较高的识别率，特别是当 SNR=-2dB，即噪声的能量高于原信号的能量时，TICNN 依然可以取得 96.47%的识别率，而相同情况下，当 mini-batch 大小为 100 时，仅取得了 88.39%的识别率；
- 3) 极小的 mini-batch 虽然在训练时给 TICNN 模型的干扰最大，但是，在测试

集上,由极小 mini-batch 训练出的 TICNN 模型的标准差,明显小于由较大的 mini-batch 训练出来的 TICNN 模型的标准差,这说明极小 mini-batch 训练的模型稳定性更好。

此外, TICNN 模型的实时性也很好, Tensorflow 环境下, 单个 TICNN 模型诊断一个信号的时间仅为 1.02ms。

5.4.2 卷积核 Dropout, BN 与集成学习对 TICNN 抗噪性的影响

本节将测试卷积核 Dropout 与集成学习对 TICNN 抗噪性的影响。同时将验证, 极小 mini-batch 训练给 TICNN 带来的提升, 是通过 BN 给卷积神经网络模型添加干扰所致, 如果卷积神经网络没有使用 BN, 使用极小 mini-batch 训练将不会发挥作用。

首先保留 TICNN 整个模型的结构, 分别测试不使用 BN, 使用 BN, 以及同时使用 BN 与第一层卷积核 Dropout 三种情况下, 模型在噪声环境下的诊断率。试验中使用的 mini-batch 的大小为 10。

试验结果如图 5-10 所示, 可以看出当不使用 BN 进行训练时, 卷积神经网络的识别率很低, 每次训练好的模型的不确定度也很大。当使用了 BN 进行训练后, 卷积神经网络的抗噪能力获得了巨大的提升。例如, 在 SNR=0dB 时, 将识别率由之前的 40%提升到了 90%。当使用 BN 以及第一层卷积核 Dropout 后, 对 SNR 较低的信号, 识别率相对于只使用 BN 也有了大幅的提高, 20 次试验的标准差也明显降低。




图 5-10 TICNN 在三种模式下的识别率

最后, 使用多数同意规则, 将 5 个分类器集成, 分别作用在上述 3 种卷积神经网络上。试验结果如图 5-11 所示, 由图可知, 集成学习对识别率的提升并不明显,

但是 20 次试验结果的标准差明显降低。综上，本章的多数同意规则，主要增强了 TICNN 模型的稳定性。




图 5-11 集成 TICNN 在三种模式下的识别率

5.4.3 抗噪性比较




图 5-12 TICNN 在不同噪声环境下与其它算法的识别率对比

本节将比较 TICNN 与 FFT-SVM, FFT-MLP、FFT-DNN 以及 WDCNN 在噪声环境下的识别率，结果如图 5-12 所示。由图可知，当 SNR 较大时，TICNN、FFT-SVM 与 WDCNN 的识别率几乎一样；而当 SNR 较小时，TICNN 及集成 TICNN 模型的识别率明显高于 FFT-SVM 与 WDCNN。在 SNR=-4dB 时，集成 TICNN 比 FFT-SVM 高了超过 10%。综上，TICNN 在噪声环境中的识别率明显高于其他几种主流智能诊断算法，极大的提升了 WDCNN 的抗噪性能。

5.5 TICNN 变载情况下轴承故障诊断率分析

本节将测试变载情况下 TICNN 模型的诊断率,变载情况的描述如 4.4 节所示。通过试验比较了 TICNN 及其集成模型与 FFT-SVM, FFT-MLP, FFT-DNN 以及 WDCNN 模型在变载情况下的识别率,结果如图 5-12 所示。




图 5-13 TICNN 算法及对照算法在 6 种不同域自适应场景中的识别率

由图 5-13 可知,对于单个场景,集成 TICNN 模型在每一种场景的识别率都高于 90%,并且在每一个场景中的识别率是所有算法中最高的,这一点是 WDCNN 模型无法达到的。其中,集成 TICNN 模型对 $C \rightarrow A$ 以及 $C \rightarrow B$ 两个场景中的识别率提升最为显著,比其它最好的算法高了 10% 左右。从整体上看, TICNN 在 6 种变载环境中的平均识别率达到了 95.5%,比 WDCNN 模型的平均识别率提高了 5.5%。集成 TICNN 模型的平均识别率更是达到了 96.1%,甚至高于经过 AdaBN 领域自适应后的 WDCNN 模型,并且前者没有使用任何领域自适应算法。综上, TICNN 模型极大的提升了 WDCNN 的变负载自适应能力。

5.6 TICNN 模型可视化分析

为了更好地理解 TICNN 模型,本节利用可视化技术,探究 TICNN 高性能的原因。

5.6.1 第一层卷积核可视化

本节可视化 TICNN 模型第一层的 16 个卷积核。图 5-14 a) 为第一层卷积核权值大小的可视化, 图 5-14 b) 为第一层卷积核在频域上的表达 (使用快速傅里叶变换)。

由频域表达可以看出, TICNN 的第一层卷积核几乎全部提取中频段的特征, 只有部分卷积核同时提取了中低频特征。值得注意的是, 卷积核 2、9、10 与 11 (从左往右, 自上而下排序) 提取的第一、二共振频率的位置几乎一致, 卷积核 3、6、7、10 与 13 也呈现出相同的特点。但从观察相应的时域信号, 这些卷积核的相位明显不一致。

鉴于振动信号的相位不确定性, TICNN 模型使用多个卷积核提取相同频率的特征, 可以理解为获取位置无关的特征。




图 5-14 TICNN 第一层卷积核可视化: a) 第一层卷积核, b) 频域上的表达

5.6.2 神经元可视化

图 5-15 可视化了被诊断信号在 TICNN 所有卷积激活层以及全连接激活层的神经元表达。作为对比, 同时可视化了具有相同结构的 WDCNN 模型 (6 个卷积层)。两个网络的输入信号均为 SNR=0dB、轴承外圈缺陷为 0.021inch 的振动信号。

由图 5-15 可以看出, 相同的信号在两种网络结构中, 神经元的激活状态差别很大。特别是第一层, TICNN 中大多数神经元呈红色, 即神经元被激活的程度很高; 而 WDCNN 模型的只有原始信号中振幅发生剧烈变化时, 才会激活神经元。因此, WDCNN 模型倾向于学习一种稀疏表达 (sparse representation), 而 TICNN 倾向于学习一种稠密表达 (dense representation)。

鉴于 WDCNN 模型与 TICNN 模型在抗噪性上的较大差异, 可以初步猜测信号, TICNN 模型前几层的稠密表达对其性能的提升起很关键的作用。




图 5-15 SNR=0dB 下轴承外圈缺陷为 0.021inch 的振动信号，在 a) TICNN 与 b) WDCNN 所有卷积层以及全连接层神经元表达

5.6.3 分类过程可视化

本节可视化了 SNR=0dB 测试集 D 所有样本，在 TICNN 所有卷积层与全连接层的特征表达经过 t -SNE 降成 2 维后的分布，如图 5-16 所示。有 3 点值得关注：

1) 随着 TICNN 模型网络层数的增加，信号在每一层的特征的可分性越来越强，说明了深度结构的必要性。

2) 最后一层中，内圈损伤 0.007 inch 和 0.021 inch 的信号特征表达有部分重合，这表明 TICNN 模型在噪声增多时，识别率下降，主要是对这两类信号的判别能力不够。

3) 与 WDCNN 不同，样本在 TICNN 第一个卷积层的表达没有表现出任何的可分性。这一层的操作类似于一种数据白化 (whiten) 操作，去除了数据的相关性。在之后的卷积层操作中，各类样本重新找到了各自的主成分，样本之间逐渐呈现出可分性。这个过程，与当下最流行的领域自适应算法 CORAL^[53]的思想很相似，CORAL 是先给数据“去相关” (decorrelate)，然后根据目标领域的信息进行“再相关” (re-correlate) 操作。这也说明了为什么 TICNN 可以具有很好的领域自适应能力。




图 5-16 SNR=0dB 的测试集 D 在所有卷积层与全连接层表达经过 t-SNE 可视化之后的分布图

5.7 本章小结

本章提出了基于训练干扰的 TICNN 模型。描述了 TICNN 模型的结构，详细阐述了使用卷积核 Dropout 算法，极小批量训练与多数同意规则的原因，给出了给算法的实施方案。通过试验，验证了 TICNN 模型具有很强的抗噪能力与变负载自适应性能。通过可视化技术，分析了 TICNN 模型的能够获得高性能的原因。TICNN 不依赖测试样本的信息，为提高故障诊断模型的自适应能力提供了一种新的思路。

结论

本文针对轴承故障诊断过于依赖人工特征提取，不能满足当下机械大数据时代的智能化、自动化的需求的问题，提出了一系列基于卷积神经网络的轴承故障诊断算法。算法在第三方标准轴承数据库 CWRU 数据集上取得了优异的结果，在识别率、抗噪性以及变负载自适应性上，均优于当前最具代表性的 DNN 算法。本文的研究工作总结如下：

1) 首次提出直接作用在时域振动信号上的卷积神经网络模型，对轴承进行故障诊断。该模型有两个卷积层，无需人工特征提取，可以自动学习对诊断有益的特征。该算法在 CWRU 轴承数据库上的识别率达到 99% 以上。

2) 提出了用于轴承故障诊断深度卷积神经网络统一架构：WDCNN。WDCNN 模型层数多，参数少，表达能力强，易于设计与训练。WDCNN 可以在 CWRU 轴承数据库达到 $100 \pm 0\%$ 的识别率。

3) 提出利用 AdaBN 领域自适应性算法改进 WDCNN。对于 CWRU 轴承数据库，改进算法在 $\text{SNR}=-4\text{dB}$ 环境中可以达到 90% 以上的识别率，在变负载环境下的平均识别率可以达到 95.9%。此外，利用可视化技术，展示了 WDCNN 的数据分析过程。

4) 提出利用训练干扰与集成学习增强 WDCNN 在噪声与变负载环境下的轴承故障诊断性能。改进算法弥补了 AdaBN 算法依赖测试集统计学信息的不足。对 CWRU 轴承数据库，在噪声与振动信号能量相等时，可以取得 98% 的识别率，在变负载环境下的平均识别率可以达到 96.1%。

在以后的工作中，有两点值得展望：1) 可以将提出的基于卷积神经网络的轴承故障诊断模型，用在齿轮，阀门等零件的故障诊断上；2) 可以结合长短时记忆网络^[55]，对轴承进行故障预测。

参考文献

- [1] 韩宝珠. 基于小波分析和在线极限学习机的滚动轴承故障诊断方法研究[D]. 北京交通大学, 2016.
- [2] <http://www.cae.cn/cae/html/files/2015-10/29/20151029105822561730637.pdf>
- [3] 雷亚国, 贾峰, 周昕, 林京. 基于深度学习理论的机械装备大数据健康监测方法[J]. 机械工程学报, 2015, (21): 49-56.
- [4] 李国杰, 程学旗. 大数据研究: 未来科技及经济社会发展的重大战略领域——大数据的研究现状与科学思考[J]. 中国科学院院刊, 2012, (06): 647-657.
- [5] 张润林. 旋转机械故障机理与诊断技术[M]. 北京: 机械工业出版社, 2002.
- [6] 从飞云. 基于滑移向量序列奇异值分解的滚动轴承故障诊断研究[D]. 上海交通大学, 2012.
- [7] 廖强. 约束独立分量和多小波分析在滚动轴承故障诊断中的应用[D]. 电子科技大学, 2016.
- [8] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. Nature, 2015, 521(7553): 436-444.
- [9] Rai V K, Mohanty A R. Bearing fault diagnosis using FFT of intrinsic mode functions in Hilbert–Huang transform[J]. Mechanical Systems and Signal Processing, 2007, 21(6): 2607-2615.
- [10] Lou X, Loparo K A. Bearing fault diagnosis based on wavelet transform and fuzzy inference[J]. Mechanical systems and signal processing, 2004, 18(5): 1077-1095.
- [11] Yu Y, Junsheng C. A roller bearing fault diagnosis method based on EMD energy entropy and ANN[J]. Journal of sound and vibration, 2006, 294(1): 269-277.
- [12] Samanta B, Al-Balushi K R. Artificial neural network based fault diagnostics of rolling element bearings using time-domain features[J]. Mechanical systems and signal processing, 2003, 17(2): 317-328.
- [13] Konar P, Chattopadhyay P. Bearing fault detection of induction motor using wavelet and Support Vector Machines (SVMs)[J]. Applied Soft Computing, 2011, 11(6): 4203-4211.
- [14] Li B, Chow M Y, Tipsuwan Y, et al. Neural-network-based motor rolling bearing fault diagnosis[J]. IEEE transactions on industrial electronics, 2000, 47(5): 1060-1069.
- [15] Muralidharan V, Sugumaran V. A comparative study of Naïve Bayes classifier and Bayes net classifier for fault diagnosis of monoblock centrifugal pump using wavelet analysis[J]. Applied Soft Computing, 2012, 12(8): 2023-2029.
- [16] Pandya D H, Upadhyay S H, Harsha S P. Fault diagnosis of rolling element bearing with intrinsic mode function of acoustic emission data using APF-KNN[J]. Expert

- Systems with Applications, 2013, 40(10): 4137-4145.
- [17] Verma N K, Gupta V K, Sharma M, et al. Intelligent condition based monitoring of rotating machines using sparse auto-encoders[C]//Prognostics and Health Management (PHM), 2013 IEEE Conference on. IEEE, 2013: 1-7.
- [18] Harmouche J, Delpha C, Diallo D. Improved fault diagnosis of ball bearings based on the global spectrum of vibration signals[J]. IEEE Transactions on Energy Conversion, 2015, 30(1): 376-383.
- [19] Mbo'o C P, Hameyer K. Fault diagnosis of bearing damage by means of the linear discriminant analysis of stator current features from the frequency selection[J]. IEEE Transactions on Industry Applications, 2016, 52(5): 3861-3868.
- [20] Georgoulas G, Nikolakopoulos G. Bearing fault detection and diagnosis by fusing vibration data[C]//Industrial Electronics Society, IECON 2016-42nd Annual Conference of the IEEE. IEEE, 2016: 6955-6960.
- [21] Janssens O, Slavkovikj V, Vervisch B, et al. Convolutional neural network based fault detection for rotating machinery[J]. Journal of Sound and Vibration, 2016, 377: 331-345.
- [22] He M, He D. Deep Learning Based Approach for Bearing Fault Diagnosis[J]. IEEE Transactions on Industry Applications, 2017, 53(3): 3057-3065.
- [23] Junbo T, Weining L, Juneng A, et al. Fault diagnosis method study in roller bearing based on wavelet transform and stacked auto-encoder[C]//The 27th Chinese Control and Decision Conference (2015 CCDC). IEEE, 2015: 4608-4613.
- [24] Sun W, Shao S, Zhao R, et al. A sparse auto-encoder-based deep neural network approach for induction motor faults classification[J]. Measurement, 2016, 89: 171-178.
- [25] Gan M, Wang C. Construction of hierarchical diagnosis network based on deep learning and its application in the fault pattern recognition of rolling element bearings[J]. Mechanical Systems and Signal Processing, 2016, 72: 92-104.
- [26] Jia F, Lei Y, Lin J, et al. Deep neural networks: A promising tool for fault characteristic mining and intelligent diagnosis of rotating machinery with massive data[J]. Mechanical Systems and Signal Processing, 2016, 72: 303-315.
- [27] LECUN Y, BOTTOU L, BENGIO Y. Gradient-based learning applied to document recognition [J/OL][J]. Proceedings of the IEEE, 2016, 86(11): 2278-2324.
- [28] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[C]//Advances in neural information processing systems. 2012: 1097-1105.
- [29] <https://www.technologyreview.com/s/513696/deep-learning/>
- [30] He K, Zhang X, Ren S, et al. Deep residual learning for image

- recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778.
- [31]Aytar Y, Vondrick C, Torralba A. SoundNet: Learning Sound Representations from Unlabeled Video[C]// Annual Conference on Neural Information Processing Systems. 2016:892-900.
- [32]Silver D, Huang A, Maddison C J, et al. Mastering the game of Go with deep neural networks and tree search[J]. Nature, 2016, 529(7587): 484-489.
- [33]Esteva A, Kuprel B, Novoa R A, et al. Dermatologist-level classification of skin cancer with deep neural networks[J]. Nature, 2017, 542(7639): 115-118.
- [34]Goodfellow I, Bengio Y, Courville A. Deep learning[M]. MIT Press, 2016.
- [35]Kingma D, Ba J. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.
- [36]<http://csegroups.case.edu/bearingdatacenter/pages/welcome-case-western-reserve-university-bearing-data-center-website>
- [37]Smith W A, Randall R B. Rolling element bearing diagnostics using the Case Western Reserve University data: A benchmark study[J]. Mechanical Systems and Signal Processing, 2015, 64: 100-131.
- [38]Abadi M, Agarwal A, Barham P, et al. Tensorflow: Large-scale machine learning on heterogeneous distributed systems[J]. arXiv preprint arXiv:1603.04467, 2016.
- [39]Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [40]Szegedy C, Ioffe S, Vanhoucke V, et al. Inception-v4, inception-resnet and the impact of residual connections on learning[J]. arXiv preprint arXiv:1602.07261, 2016.
- [41]Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[J]. arXiv preprint arXiv:1502.03167, 2015.
- [42]Laha S K. Enhancement of fault diagnosis of rolling element bearing using maximum kurtosis fast nonlocal means denoising[J]. Measurement, 2017, 100: 157-163.
- [43]Kumar H S, Pai P S, Sriram N S, et al. Comparison of denoising schemes and dimensionality reduction techniques for fault diagnosis of rolling element bearing using wavelet transform[J]. International Journal of Manufacturing Research, 2016, 11(3): 238-258.
- [44]Li W, Zhang S, Rakheja S. Feature Denoising and Nearest–Farthest Distance Preserving Projection for Machine Fault Diagnosis[J]. IEEE Transactions on Industrial Informatics, 2016, 12(1): 393-404.
- [45]Lu W, Liang B, Cheng Y, et al. Deep model based domain adaptation for fault diagnosis[J]. IEEE Transactions on Industrial Electronics, 2017, 64(3): 2296-2305.
- [46]Xie J, Zhang L, Duan L, et al. On cross-domain feature fusion in gearbox fault

- diagnosis under various operating conditions based on transfer component analysis[C]//Prognostics and Health Management (ICPHM), 2016 IEEE International Conference on. IEEE, 2016: 1-6.
- [47]Li Y, Wang N, Shi J, et al. Revisiting Batch Normalization For Practical Domain Adaptation[J]. arXiv preprint arXiv:1603.04779, 2016.
- [48]Amar M, Gondal I, Wilson C. Vibration spectrum imaging: A novel bearing fault classification approach[J]. IEEE Transactions on Industrial Electronics, 2015, 62(1): 494-502.
- [49]Maaten L, Hinton G. Visualizing data using t-SNE[J]. Journal of Machine Learning Research, 2008, 9(Nov): 2579-2605.
- [50]Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: A simple way to prevent neural networks from overfitting[J]. The Journal of Machine Learning Research, 2014, 15(1): 1929-1958.
- [51]Keskar N S, Mudigere D, Nocedal J, et al. On large-batch training for deep learning: Generalization gap and sharp minima[J]. arXiv preprint arXiv:1609.04836, 2016.
- [52]Zhou Z H. Ensemble methods: foundations and algorithms[M]. CRC press, 2012.
- [53]Sun B, Saenko K. Deep coral: Correlation alignment for deep domain adaptation[C]//Computer Vision–ECCV 2016 Workshops. Springer International Publishing, 2016: 443-450.
- [54]Patel V M, Gopalan R, Li R, et al. Visual domain adaptation: A survey of recent advances[J]. IEEE signal processing magazine, 2015, 32(3): 53-69.
- [55]Gers F A, Schmidhuber J, Cummins F. Learning to forget: Continual prediction with LSTM[J]. 1999.

攻读学位期间发表的学术论文

- [1] **Zhang W**, Peng G, Li C, et al. A New Deep Learning Model for Fault Diagnosis with Good Anti-Noise and Domain Adaptation Ability on Raw Vibration Signals[J]. Sensors, 2017, 17(2): 425. (**SCI, IF: 2.677, WOS:000395482700207**, 对应文中第 3、4 章)
- [2] **Zhang W**, Li C, Peng G, et al. A Deep Convolutional Neural Network with New Training Methods for Bearing Fault Diagnosis under Noisy Environment and Different Working Load [J]. Mechanical Systems and Signal Processing. (**SCI, IF: 4.116**, 已录用, 对应文中第 5 章)
- [3] Li C, **Zhang W**, Peng G, et al. Bearing Fault Diagnosis using Fully-connected Winner-Take-All Autoencoder. IEEE Access (**SCI, IF: 3.244**, 已录用)
- [4] **Zhang W**, Peng G, Li C. Rolling Element Bearings Fault Intelligent Diagnosis Based on Convolutional Neural Networks Using Raw Sensing Signal[C]//Advances in Intelligent Information Hiding and Multimedia Signal Processing: Proceeding of the Twelfth International Conference on Intelligent Information Hiding and Multimedia Signal Processing, Nov., 21-23, 2016, Kaohsiung, Taiwan, Volume 2. Springer International Publishing, 2017: 77-84.(**EI, 20165103138998**, 对应文中第 2 章)
- [5] **Zhang W**, Peng G, Li C. Bearings Fault Diagnosis Based on Convolutional Neural Networks with 2-D Representation of Vibration Signals as Input[C]//MATEC Web of Conferences. EDP Sciences, 2017, 95: 13001. (**EI, 20170803381038**)

致 谢

How time flies! 六年前，当我踏入哈工大的第一天，就被这巍巍高耸的主楼所吸引。能在素以办学立意高峻、名师荟萃、校风优良、人才辈出著称于世的学校学习，是我一生的荣幸。六年的锻炼，使我找到了自我，拥有了自信，看到了青春与希望。感谢机电控制系，感谢机电学院，更感谢我的母校！

在这里，首先感谢我的导师彭高亮老师。彭老师知识渊博，视野开阔，勤奋刻苦，对学生尽心尽责。在彭老师的指导下，我学到很多，也成长很快。彭老师在完成论文的过程中提供了很多宝贵意见，谢谢老师！

感谢计算机学院的刘绍辉老师、左旺孟老师在计算机视觉以及深度学习算法上给予我的帮助！

感谢实验室的孙瑜、张著军等师兄，蔡静楠、邴宇涵、郝宝坤等同学与李传浩、吉孟宇、陈远航等师弟在我完成论文的过程中给予我的帮助！

感谢凯斯西储大学轴承数据中心为本文提供轴承诊断数据！

最后，特别感谢我的父母对我在学业与生活上的支持，你们是激励我在学术道路上前行的坚强后盾，谢谢你们！